

공학 석사 학위논문

ECG 신호 및 측정값을 활용한 뇌졸중
분류용 하이브리드 퓨전 멀티모달
프레임워크

A Hybrid Fusion Multimodal Framework for Stroke
Classification Using ECG Signals and Measurements

임 소 윤(Im, So Yun)

컴퓨터공학과(Department of Computer Engineering)

컴퓨터공학전공(Major in Computer Engineering)

한림대학교 대학원

(Graduate School, Hallym University)

공학 석사 학위논문

ECG 신호 및 측정값을 활용한 뇌졸중
분류용 하이브리드 퓨전 멀티모달
프레임워크

A Hybrid Fusion Multimodal Framework for Stroke
Classification Using ECG Signals and Measurements

임 소 윤(Im, So Yun)

컴퓨터공학과(Department of Computer Engineering)

컴퓨터공학전공(Major in Computer Engineering)

한림대학교 대학원

(Graduate School, Hallym University)

김 유 섭 교수지도
공학 석사 학위논문

임 소 윤의 석사학위논문을 합격으로 판정함

2026년 06월 16일

심사위원장 허 종 욱

(성함 기재 후 날인 또는 서명)

심사위원 신 범 주

(성함 기재 후 날인 또는 서명)

심사위원 김 유 섭

(성함 기재 후 날인 또는 서명)



목차

제1장 서론	1
1. 연구 배경 및 필요성	1
2. 주요 연구 내용	3
제2장 연구 자료	5
1. 연구 대상 및 ECG 데이터 셋	5
2. ECG 피쳐 셋 구성	7
제3장 연구 방법	11
1. ECG 신호 분류 모델	12
2. ECG 피쳐 분류 모델	15
3. 하이브리드 퓨전 멀티모달 프레임워크	17
제4장 실험 결과	25
1. 학습 설정	25
2. 단일모달 모델 성능 평가	27
3. ECG 피쳐 분석 및 최종 구성	30
4. 성능 비교 및 모델 해석	33
제5장 절제 실험 및 검증 분석	42
제6장 논의	45
제7장 결론	49
참 고 문 헌	50
영 문 초 록	59
부 록	61

표목차

표 1. ECG 피처 설명	8
표 2. ECG 신호 기반 모델의 성능 비교	27
표 3. 전체 50개 피처의 유의성 순위 기반 피처 섷별 MLP 성능 비교	29
표 4. 피처 그룹별 제거 실험 결과	32
표 5. 단일모달 및 멀티모달 모델 성능 비교	33
표 1-1. MUSE 변수의 통계 분석 결과	61
표 1-2. Extracted 변수의 통계 분석 결과	62
표 2-1. 그룹별 유의성 순위 기반 피처 섷에 따른 KNN 성능 비교	63
표 2-2. 그룹별 유의성 순위 기반 피처 섷에 따른 MLP 성능 비교	64
표 3-1. 뇌졸중군과 비뇌졸중군의 피처 결측률 비교	65
표 3-2. 데이터 조건에 따른 피처 결측 양상	65
표 3-3. MUSE 피처와 Extracted 피처 간 상관관계 및 해석	66
표 4-1. 임베딩 크기 구성에 따른 성능 비교	67
표 4-2. Early Fusion 전략별 Hybrid Fusion 모델 성능 비교	68
표 4-3. 임계값 설정에 따른 Hybrid Fusion 모델 성능 비교	68
표 5-1. Signal-Only 모델과 Hybrid Fusion 모델 간 통계적 비교	69
표 5-2. 성별 및 연령에 따른 하위그룹 성능	70
표 5-3. Temporal Holdout 평가 데이터 섷	70
표 5-4. Temporal Holdout 분류 성능	71

그림목차

그림 1. 12-lead ECG 측정 과정 예시	5
그림 2. ECG 데이터 셋 구축 과정	6
그림 3. ECG 신호의 주요 파형 구성 요소	7
그림 4. ECG 피치의 통계적 유의성 순위	10
그림 5. Hybrid Fusion 모델 전체 구조	11
그림 6. 신호 분류 모델 세부 구조	14
그림 7. 피쳐 분류 모델 세부 구조	16
그림 8. Interaction Early Fusion 모델 구조	19
그림 9. Raw Interaction Branch 세부 구조	21
그림 10. Hybrid Fusion 모델 최종 예측 과정	23
그림 11. 단일모달 및 멀티모달 모델 성능 비교	34
그림 12. Signal-Only 모델과 Hybrid Fusion 모델의 ROC 곡선 비교	35
그림 13. Hybrid Fusion 모델의 Calibration Curve	36
그림 14. 예측 결과별 Grad-CAM 히트맵 Lead II 샘플 비교	37
그림 15. SHAP 기반 피쳐 중요도	38
그림 16. SHAP Beeswarm Plot	38
그림 17. Raw Interaction Branch의 self-attention 히트맵	40

ECG 신호 및 측정값을 활용한 뇌졸중 분류용 하이브리드 퓨전 멀티모달 프레임워크

2026.

석사학위논문

임소윤

컴퓨터공학과

지도교수: 김유섭

뇌졸중은 전 세계적으로 주요한 사망 및 장기 장애 원인 중 하나이며, 조기에 식별하는 것이 중요하다. 심전도(ECG)는 뇌졸중 관련 이상을 탐지할 수 있는 비침습적 도구로 주목받고 있으나, ECG 신호만 사용하는 단일모달 접근은 뇌졸중 관련 ECG의 특징을 충분히 반영하는 데 한계가 있다. 본 연구에서는 뇌졸중 분류를 위해 ECG로부터 얻은 두 종류의 정보, 즉 원시 12-lead ECG 신호와 ECG에서 산출된 정량적 피처를 함께 활용하는 하이브리드 퓨전 기반 멀티모달 프레임워크를 제안한다. 해당 프레임워크는 두 단계로 구성된다. 첫째, 신호 인코더, 피처 인코더, 그리고 Raw Interaction Branch로 이루어진 Interaction Early Fusion 모델을 통해 원시 데이터 수준과 표현 수준 모두에서 모달 간의 상호작용을 학습한다. 둘째, Signal-Only 모델, Feature-Only 모델, 그리고 Interaction Early Fusion 모델의 logit을 평균하여 통합하는 Hybrid Fusion을 적용한다. 제안 모델은 AUC 0.832와 Recall 82.7%를 달성하였으며, Signal-Only 모델 대비 AUC는 0.034, Recall은 6.7%p 향상되었다.

주제어 : 뇌졸중 분류, 심전도, ECG 측정값, 멀티모달 학습, 하이브리드 퓨전

제1장 서론

1. 연구 배경 및 필요성

뇌졸중은 뇌혈관의 폐색 또는 파열로 인해 뇌 조직으로의 혈류 공급이 방해되면서 발생하는 신경학적 질환이다. 뇌 내에서 혈전이 형성되면 혈류가 방해되어 동맥 폐색을 유발하고, 허혈성 뇌졸중은 혈전 또는 색전에 의한 동맥 폐색으로 발생하며, 출혈성 뇌졸중은 혈관 파열에 따른 두개내 출혈로 인해 발생한다. 이로 인한 산소 및 영양 공급 장애는 신경세포 손상과 사멸을 초래할 수 있으며, 이후 인지기능 저하, 치매, 우울증과 같은 후유증으로 이어질 수 있다 [1]. 뇌졸중은 전 세계적으로 두 번째로 높은 사망 원인이며, 장애보정수명(Disability-Adjusted Life Years, DALYs)¹⁾의 세 번째 주요 원인으로 보고되고 있다. 1990년부터 2021년 사이 뇌졸중 발생 건수는 70.0%, 뇌졸중 관련 사망은 44.0%, 유병률은 86.0%, DALYs는 32% 증가하였다. 또한 전 세계적으로 뇌졸중으로 인한 경제적 부담은 약 8,900억 달러(세계 GDP의 0.66%)에 이를 것으로 추정된다 [2]. 따라서 증가하는 사망률을 감소시키고 막대한 경제적 부담을 완화하기 위해 뇌졸중의 조기 진단에 대한 연구가 매우 중요하다.

일반적으로 뇌졸중 진단에는 컴퓨터단층촬영(computed tomography, CT), 자기공명영상(magnetic resonance imaging, MRI), 혈액 검사, 심전도(electrocardiography, ECG) 등 다양한 임상 검사가 활용된다 [3-5]. 이 중 ECG는 심장의 전기적 활동을 측정하는 중요한 의료 도구로, 부정맥, 심박 및 심근 질환, 전해질 불균형, 폐 질환 등 다양한 심장 관련 질환을 탐지하고 진단하는 데 활용된다 [6]. 뇌졸중은 신경세포에

1) 장애보정수명(DALYs)은 조기사망으로 인한 손실된 생존연수와 장애로 인한 건강 손실 기간을 합산하여 질병 부담을 나타내는 지표이다.

빠르고 영구적인 손상을 유발하기 때문에 즉각적인 인지과 치료가 매우 중요하며 [7], 따라서 신속한 진단이 필수적이다. 이러한 맥락에서 ECG는 간단하고 비침습적이며, 빠르고 비용 효율적인 진단 방법이라는 실용적인 장점을 가진다. 기존 연구에서는 뇌졸중 환자에서 T파 변화, QTc 연장, 부정맥 등과 같은 ECG 이상이 자주 관찰된다고 보고되었으며, 이는 ECG가 뇌졸중 조기 탐지 도구로 활용될 수 있는 가능성을 시사한다 [8-10].

여러 연구에서는 ECG를 활용하여 뇌졸중을 예측하거나 분류하려는 시도가 이루어져 왔다. 연구 [3]에서는 평균 연령이 약 70대인 뇌졸중 환자군과 대조군으로 구성된 연구 표본을 대상으로 ECG 측정값의 통계적 유의성을 분석하고, 다양한 머신러닝 분류기를 통해 뇌졸중 분류 성능을 평가하였다. 그 결과 k-최근접 이웃(k-nearest neighbors, KNN) [11] 분류기가 96.6%의 가장 높은 정확도를 달성하였다 [3]. 한편 연구 [12]에서는 30세 이상 임상 환자들로부터 수집된 대규모 ECG 데이터를 기반으로 ECG-MACE 모델을 제안하였다. 이 모델은 ResNet-18 기반의 멀티태스크 구조를 사용하여 심부전과 전체 사망률 예측에서 각각 AUC 0.90과 0.89의 성능을 달성하였으나, 뇌졸중 예측 성능은 상대적으로 낮은 AUC 0.76을 보였다 [12]. 최근에는 단일 모달리티 기반 ECG 분석의 한계를 극복하기 위해 멀티모달 학습 접근 방식이 연구되고 있다. 연구 [13]에서는 ECG 신호와 임상 정보(나이, 성별, 동반 질환 등)를 Transformer 기반 구조로 통합하여 심방세동 절제술 이후 재발을 예측하였으며, 단일 모달리티 모델보다 유의미하게 높은 AUC 성능을 보였다. 또한 연구 [14]에서는 CNN 기반 모델을 활용하여 ECG 신호와 HRV 및 인구통계학적 정보를 결합함으로써 심방세동 탐지 성능이 향상됨을 보고하였다.

그러나 연구 대상이 실제 임상 환자가 아닌 모집된 코호트나 선별된 집단으로 구성된 경우, 보고된 높은 성능이 실제 임상 환경에 그대로 일반화되지 않을 가능성이 있다 [15]. 또한 임상 코호트를 사용한 연구에서도 뇌졸중에 특화된 예측에 대한 연구는 제한적이어서 뇌졸중 분류 성능이 충분히 높지 않은 경우가 많으며, 이에 대한 추

가 연구가 필요하다. 또한 ECG 측정값 기반 단일모달 모델은 신호의 파형 정보를 반영하기 어렵고, ECG 신호 기반 단일모달 모델은 ECG 측정값에 포함된 정량적 정보를 직접적으로 활용하지 못한다는 한계가 있다 [16,17].

이러한 한계를 개선하기 위해 본 연구에서는 다음을 수행하였다. 첫째, ECG를 사용하여 뇌졸중 분류에 특화된 모델을 구축하였다. 둘째, 실제 임상 코호트 데이터를 활용하여 제안 모델의 일반화 가능성을 확인하고자 하였다. 셋째, 12-lead ECG 신호와 ECG 측정값을 함께 활용하여, 하나의 ECG 기록에서 획득 가능한 서로 다른 형태의 정보를 통합하는 멀티모달 접근법을 제안하였다. 넷째, 멀티모달 정보의 효과적인 통합을 위해 Interaction Early Fusion 모델을 제안하고, 이를 Signal-Only 및 Feature-Only 모델과 late fusion 방식으로 결합하여 Hybrid Fusion 프레임워크를 구축하였다.

2. 주요 연구 내용

기존 ECG 기반 멀티모달 연구들은 ECG 신호와 임상 정보(환자 특성, 구조화된 임상 변수, 전자의무기록 등)를 결합하는 방식에 초점을 맞추어 왔다 [18]. 그러나 이러한 접근은 임상 정보의 가용성이 의료기관이나 데이터 수집 환경에 따라 제한될 수 있다는 한계가 있다 [19,20]. 이에 반해 본 연구는 최소한의 임상 정보인 성별만을 사용하여 임상 정보 의존도를 최소화하고, ECG 기반의 두 가지 모달리티인 원시 12-lead ECG 신호와 ECG 측정값을 활용한다는 점에서 차별성을 가진다. ECG 측정값은 ECG 장비에서 산출된 정량적 지표를 의미하며, 본 연구에서 이를 모델 입력 변수로 사용하였으므로 ECG 피처로 지칭하였다.

이를 위해 본 연구에서는 하이브리드 퓨전 기반 멀티모달 분류 프레임워크를 제안한다. 제안한 프레임워크는 Interaction Early Fusion과 Hybrid Fusion의 두 단계

로 구성된다. 먼저, Interaction Early Fusion 모델은 ECG 신호 인코더와 피쳐 인코더에 더해 Raw Interaction Branch를 포함하여, 각 모달리티의 독립적인 표현을 학습하는 동시에 원시 데이터 수준에서 신호와 피쳐의 상호작용을 반영하도록 설계되었다. 이후 Interaction Early Fusion 모델은 Hybrid Fusion 단계에서 Signal-Only 모델, Feature-Only 모델과 late fusion 방식으로 결합하여 최종 예측값을 얻는다. 이를 통해 early fusion 기반의 상호작용 학습과 late fusion 기반의 예측 통합 효과를 함께 활용하였다. 제안한 프레임워크는 ECG 기반 정보만으로도 뇌졸중 분류 성능을 향상시킬 수 있음을 확인하였으며, 실제 임상 환경에서 조기 위험 선별을 지원하는 비침습적 의사결정 보조 도구로서의 활용 가능성을 제시한다.

본 논문의 나머지 구성은 다음과 같다. 제2장에서는 데이터 셋, 전처리 절차 및 ECG 피쳐 구성 과정을 설명한다. 제3장에서는 ECG 신호 모델과 ECG 피쳐 모델을 설명하고, 이를 통합한 하이브리드 퓨전 멀티모달 프레임워크의 구조를 기술한다. 제4장에서는 주요 실험 결과와 해석 가능성 분석 결과를 제시한다. 제5장에서는 절제 실험 및 검증 분석 결과를 요약하고, 제6장에서는 연구 결과의 의의 및 임상적 시사점과 한계를 논의한다. 마지막으로 제7장에서는 본 논문의 결론을 제시한다.

제2장 연구 자료

1. 연구 대상 및 ECG 데이터 셋




그림 1. 12-lead ECG 측정 과정 예시

본 연구에는 2011년 1월부터 2021년 6월까지 한림대학교 춘천성심병원에 입원한 뇌졸중 환자 2,421명과, 2015년 1월부터 2019년 12월까지 입원한 비뇌졸중 대조군 환자 2,509명이 포함되었다. 제공된 ECG 기록은 뇌졸중 환자군 2,540건, 비뇌졸중 환자군 2,689건으로 구성되었다. MAC55, MAC2K, MAC5K, M1200 장비를 사용하여 측정되었으며, GE Healthcare MUSE ECG Management System²⁾을 통해 처리되었다. 각 파일에는 500Hz로 샘플링된 10초 길이의 12-lead ECG 신호, 기본 임상 정보, 그리고 ECG 피처가 포함되어 있다. 그림 1은 ECG 장비를 이용한 12-lead ECG 측정 과정의 예시를 보여준다. 12-lead ECG는 신체 표면에 부착된 10개의 전극을 이용하여 심장의 전기적 활동을 여러 방향에서 기록하는 검사이다. 양쪽 팔과 다리에

2) MUSE ECG Management System은 GE HealthCare의 심전도 정보 관리 시스템으로, 다양한 심장검사 데이터를 통합 관리하고 ECG 파형, 측정값 및 판독문을 저장·조회할 수 있도록 지원한다.

부착된 사지 전극으로부터는 I, II, III, aVR, aVL, aVF의 6개 사지유도가 산출되며, 흉부에 부착된 6개의 전극으로부터는 V1-V6의 흉부유도가 기록된다. 따라서 12-lead ECG는 10개의 전극에서 획득한 전위차를 기반으로 총 12개의 lead 파형을 구성한다 [21].




그림 2. ECG 데이터 셋 구축 과정

그림 2는 실험을 위한 데이터 셋 구성 과정을 요약한다. 임상 변수로는 성별만 사용하였다. 성별이 누락된 기록은 제외하였으며, ECG 피처에서 발생한 결측은 중앙값으로 대체하였다. 이때 중앙값은 학습 데이터에서만 계산하였으며, 해당 값을 검증 및 테스트 데이터에 동일하게 적용하였다. 동일 환자의 여러 ECG 중 뇌졸중과 비뇌졸중 레이블이 동시에 존재하는 경우 해당 환자의 모든 ECG 기록을 제거하였다. 그리고 동일한 입원 날짜에 측정된 여러 ECG 기록이 존재할 경우, 입원 시간과 가장 가까운 기록만 유지하였다. 길이가 5,000 샘플 기준에 맞지 않는 ECG 신호 역시 데이터 셋에서 제외하였다. 이러한 전처리 과정을 거친 후, 최종적으로 뇌졸중군 2,058명, 2,137건의 ECG와 비뇌졸중군 1,962명, 2,010건의 ECG가 분석에 사용되었다. 모델

평가를 위해 환자 단위의 5-fold 교차 검증을 사용했다. 각 fold 내에서 환자들을 8:1:1의 비율로 훈련 셋, 검증 셋, 테스트 셋으로 나누었으며, 이를 통해 동일한 환자의 심전도 데이터가 서로 다른 데이터 셋에 동시에 포함되지 않도록 했다. 본 연구는 후향적 연구로 수행되었으며, 춘천성심병원 기관생명윤리위원회(IRB No. 2021-07-009)의 승인을 받았다. 또한 익명화된 데이터를 사용하였기 때문에 연구 참여 동의는 면제되었다.

2. ECG 피쳐 셋 구성




그림 3. ECG 신호의 주요 파형 구성 요소

ECG는 시간에 따른 심장의 전기적 활동을 기록하는 생체 신호로, 파형 간격, 진폭, 축과 같은 다양한 측정값을 통해 심장의 전기적 및 생리학적 상태를 반영한다 [22]. 그림 3은 ECG 신호의 주요 파형 구성 요소와 측정 지표를 보여준다. ECG 파형은 기본적으로 P파, QRS군, T파로 구성되며, 주요 측정값은 이러한 파형 구성요소의 시간 간격, 구간, 진폭 및 축 정보로 산출된다. PR interval, QRS duration, QT interval, ST segment, RR interval 등은 심장 전기활동의 시간적 특성을 나타

표 1. ECG 피처 설명

MUSE Measurement Features (n = 19)		Extracted Features (n = 21)	
Feature name	Description	Feature name	Description
VentricularRate	심실 박동수	HR	RR 간격으로부터 산출한 심박수
AtrialRate	심방 박동수	RR-I	평균 RR 간격
GlobalRR	전체 리드에서의 평균 RR 간격	PRQ	정규화된 PR 간격
QRSCount	검출된 QRS 복합파의 개수	QRS	QRS 지속 시간
PRInterval	P파 시작, QRS 시작까지의 시간	QT	QT 간격
QRSDuration	QRS 복합파의 지속 시간	QTc	심박수 보정 QT 간격
QTInterval	Q파 시작, T파 종료까지의 시간	ST	ST 분절 지속 시간
QTCorrected	심박수 보정 QT 간격 (Bazett)	P-H	P파 진폭
QTcFrederica	심박수 보정 QT 간격	R-H	R파 진폭
PharmaRRinterval	약물 관련 RR 간격	RMSSD	연속 RR 간격 차이 제곱평균제곱근
PharmaPPinterval	약물 관련 PP 간격	SDSD	연속 RR 간격 차이 표준편차
QOnset	QRS군 시작 시점	pNN50	RR 간격 차이의 50 ms 초과 비율
QOffset	QRS군 종료 시점	LF	HRV의 저주파 성분 파워
POnset	P파 시작 시점	HF	HRV의 고주파 성분 파워
POffset	P파 종료 시점	VLF	HRV의 초저주파 성분 파워
TOffset	T파 종료 시점	LF/HF	LF와 HF 파워의 비율
PAxis	P파의 전기축	Kurtosis	ECG 진폭 분포의 첨도
RAxis	R파의 전기축	Skewness	ECG 진폭 분포의 비대칭도
TAxis	T파의 전기축	Peak value	ECG 파형의 최대 진폭
		Impulse factor	평균 진폭 대비 피크 진폭의 비율
		Crest factor	RMS ³⁾ 진폭 대비 피크 진폭의 비율

내는 대표적인 지표이다. 본 연구에서는 ECG로부터 산출된 측정값을 모델의 입력 피처로 활용하였다. 이러한 ECG 피처는 신호에서 직접 학습되는 형태적 패턴과 달리, 심장 전기활동의 시간적 간격 및 정량적 특성을 명시적으로 나타내므로 신호 데이터를 보완하는 정보원으로 사용될 수 있다.

본 연구에서는 MUSE 시스템에서 제공되는 피처와 ECG 신호로부터 추가로 추출한 Extracted 피처를 함께 사용하였다. 두 피처 그룹의 각 피처 이름과 설명은 표 1에 제시하였다. MUSE 피처는 ECG 파형의 주요 기준점을 기반으로 산출되는 시간 간격, 지속시간, 전기축 등의 정량적 특성을 나타내며, 총 19개로 구성된다. 이와 함께 MUSE 피처만으로는 반영하기 어려운 다양한 신호 기반 특성을 포함하기 위해 기

3) RMS는 root mean square의 약자로, 신호의 제곱평균제곱근을 의미하며 신호의 유효 크기를 나타낸다.

존 연구 [3]에서 제안된 21개의 피처를 신호로부터 직접 추출하고, 이를 Extracted 피처 그룹으로 정의하였다. Extracted 피처는 파형 높이, 심박변이도(Heart Rate Variability, HRV), 진폭 분포 및 피크 관련 특성을 포함한다. 신호 전처리와 피처 추출은 해당 연구에서 제시된 방법을 따랐다. 잡음 제거는 웨이블릿 변환 기반 노이즈 제거를 사용하여 수행하였으며, 기준점은 Pan-Tompkins QRS 검출 알고리즘을 이용해 탐지하였다 [23]. 다만 주파수 영역 HRV 피처인 VLF, LF, HF, LF/HF에는 별도의 방법을 적용하여 추출하였다. 일반적으로 주파수 영역 HRV 분석은 약 5분 길이의 기록을 기준으로 수행되지만, 본 연구의 ECG는 10초 길이의 초단기 구간이므로 RR 간격 변동의 주파수 성분을 충분히 추정하기 어렵다 [24]. 이를 보완하기 위해 본 연구에서는 자기회귀(autoregressive, AR) 모델을 적용하여 주파수 영역 HRV 피처를 추정하였다. AR 방법은 짧은 데이터 구간에서도 비교적 안정적인 스펙트럼 추정을 가능하게 한다 [25].

이렇게 MUSE와 Extracted 두 그룹의 피처 외에도 일부 변수를 추가로 구성하였다. 결측 자체가 임상적으로 의미를 가질 수 있다는 점을 고려하여 [26], 결측값이 존재하는 피처에 대해 결측 지시 변수 (missingness indicator, MI)를 추가하였다. MI 변수는 해당 값이 결측인 경우 1, 관측된 경우 0으로 정의하였으며, 총 9개가 생성되었다. 또한 QT 간격은 성별에 따라 차이가 존재할 수 있으므로 [27], MUSE 그룹에 임상 변수인 성별을 추가하였다. 따라서 초기 피처 셋은 MUSE 그룹 변수 20개, Extracted 그룹 변수 21개, MI 변수 9개를 포함하여 총 50개로 구성되었다.

실험에 사용된 모든 변수에 대해 뇌졸중 환자군과 비뇌졸중 환자군 간의 통계적 차이를 분석하였다. 연속형 변수는 독립표본 t-test를 사용하였고 [28], 범주형 변수는 카이제곱 검정을 사용하였다 [29]. $p\text{-value} < 0.05$ 인 변수는 통계적으로 유의한 것으로 간주하였다. 세부적인 통계 분석 결과는 부록 1의 표 1-1과 표 1-2에 제시하였다. 그림 4는 $p\text{-value}$ 기준 변수별 통계적 유의성 순위를 나타낸다. 상당수의 피처에서 $p\text{-value}$ 가 0.001보다 작게 나타났기 때문에 이를 $-\log_{10}(p\text{-value})$ 로 변환하여 시각




그림 4. ECG 피처의 통계적 유의성 순위

화하였다. 이 변환은 p-value가 작을수록 큰 값으로 표시되어, 통계적 유의성이 높은 변수일수록 상위에 위치한다. 그림 4에서 빨간 점선은 p-value 0.05에 해당하는 $-\log_{10}(p\text{-value})=1.30$ 기준선을 의미하며, 점선보다 오른쪽에 위치한 변수는 통계적으로 유의한 차이를 보인 피처로 해석할 수 있다. 전반적으로 QTcFrederica_missing, RAxis, QTcFrederica, QT(ms), TOffset 등 MUSE 피처가 상위에 많이 분포하였으며, Extracted 피처도 절반 이상이 유의한 차이를 보였다.

제3장 연구 방법

본 연구에서는 ECG 신호와 피쳐의 상호보완적 정보를 효과적으로 통합하기 위해 하이브리드 퓨전 멀티모달 프레임워크를 설계하였다. 그림 5는 제안 프레임워크의 전체 구조를 보여준다. 제안한 구조는 Signal Model Branch, Feature Model Branch, Interaction Early Fusion Model Branch로 구성된다. 최종적으로 각 브랜치에서 산출된 logit을 평균하여 최종 예측값을 생성한다.




그림 5. Hybrid Fusion 모델 전체 구조

1. ECG 신호 분류 모델

1) ECG 신호 분류 모델 선정 및 입력 구성

ECG 신호 분석에서는 CNN 기반 모델이 널리 사용되어 왔으며, PTB-XL 데이터셋을 이용한 기존 평가 연구에서도 ResNet 및 Inception 계열의 합성곱 구조가 여러 ECG 분류 과제에서 우수한 성능을 보인 것으로 보고되었다 [30]. 연구 [31]에서는 2백만 건 이상의 12-lead ECG를 이용하여 ResNet 기반 CNN 모델을 학습하였고, 주요 ECG 이상을 높은 성능으로 자동 분류할 수 있음을 보였다. ECG는 본질적으로 시간에 따른 전기적 변화를 기록한 시계열 신호이므로 1D CNN 기반 모델이 자연스러운 비교 기준이 될 수 있다. 한편 12-lead ECG는 단일 시계열이 아니라 서로 다른 방향에서 동시에 기록된 다중 lead 신호이므로, lead 축과 시간축을 함께 갖는 2차원 배열로 구성하여 2D CNN에 입력하는 접근도 제안되어 왔다. 연구 [32]에서는 12-lead ECG를 2차원 배열 형태로 구성하고 ResNet 기반 2D CNN 모델을 적용하여 lead 내부 특징과 lead 간 특징을 함께 학습하는 방법을 제안하였다. 연구 [33]에서도 12-lead ECG를 일반 이미지로 변환하지 않고, lead별 시간 신호를 행렬 형태로 배치하여 2D CNN 기반 진단 모델의 입력으로 사용하였다. 또한 ImageNet은 대규모 이미지 데이터베이스로, 다양한 비전 모델의 사전학습에 널리 활용되어 왔다 [34]. 연구 [35]에서는 ECG 분류에서 1D 신호 입력과 2D 이미지 입력을 비교하였으며, ImageNet 가중치로 초기화한 2D CNN이 대규모 ECG 데이터가 없는 조건에서 1D 방식보다 높은 성능과 안정성을 보였다고 보고하였다. 시계열 분석 전반에서도 image-pretrained 비전 모델이 시계열 분류에 유용할 수 있음이 보고된 바 있다 [36].

이러한 선행연구를 바탕으로 본 연구에서는 ECG 신호 분류를 위한 비교 모델을

CNN 기반 구조로 구성하였으며, 입력 표현 방식에 따라 1D CNN 기반 모델과 2D CNN 기반 모델을 모두 포함하였다. 비교 대상 모델은 InceptionTime, 참고문헌 [12]를 바탕으로 본 연구에서 직접 구현한 1D ResNet-18, ImageNet 사전학습 가중치를 적용한 2D ResNet-18, 그리고 ImageNet 사전학습 가중치를 적용한 2D EfficientNet-B0로 구성하였다. InceptionTime은 다양한 크기의 1D convolution kernel을 병렬적으로 적용하여 다중 시간 스케일의 파형 패턴을 학습하는 시계열 CNN 모델이며 [37], 1D ResNet-18은 ResNet의 residual block과 skip connection을 1D convolution 구조에 적용한 모델이다 [38]. EfficientNet은 네트워크의 깊이, 너비, 입력 해상도를 균형 있게 확장하는 compound scaling 전략을 기반으로 하는 CNN 계열 모델이다 [39].

1D 기반 모델은 12개의 lead를 입력 채널로 사용하고, 각 채널에 대해 5000개의 time step을 포함하는 12×5000 형태를 입력으로 사용하였다. 반면 2D 기반 모델은 선행연구 [32,33]과 같이 ECG 신호를 일반 이미지로 변환하지 않고, 12-lead ECG의 lead-time 구조를 보존한 2차원 배열 형태로 구성하였다. 구체적으로 12개 lead와 5000개 time step으로 구성된 원시 ECG 배열에 채널 차원만 추가하여 $1 \times 12 \times 5000$ 형태로 입력하였다. 이는 ECG를 이미지 자체로 간주하기 위한 것이 아니라, 시간적 파형 변화와 lead 간 패턴을 함께 학습하기 위한 방식이다. 이와 같이 구성한 ECG 배열에 ImageNet 사전학습 모델을 적용하기 위해서는, 기존 RGB 이미지 입력을 기준으로 학습된 첫 번째 입력층을 본 연구의 ECG 입력 형태에 맞게 조정할 필요가 있다. 연구 [40]에서는 ImageNet 사전학습 비전 모델을 RGB 이미지와 다른 입력 형태에 적용하기 위해, 3채널 입력 가중치를 평균 내어 단일 채널 입력층의 가중치로 사용하는 방식을 적용하였다. 이를 참고하여 본 연구에서도 2D 모델의 첫 번째 convolution layer를 기존 3채널 입력에서 1채널 입력으로 수정하였고, 기존 RGB 채널의 가중치를 평균 내어 초기화하였다. 본 연구의 분류 과제가 이진 분류이므로, 모든 모델의 최종 출력층은 하나의 logit을 생성하도록 구성하였다.

2) ECG 신호 분류 모델 구조




그림 6. 신호 분류 모델 세부 구조

본 연구에서는 신호 기반 분류 실험 결과를 바탕으로 EfficientNet-B0를 신호 분류 모델로 선정하였다. 그림 6은 신호 분류 모델의 세부 구조를 보여준다. 입력 형태로 변환된 ECG 신호는 먼저 입력에 맞게 1채널로 수정된 첫 번째 convolution layer와 Batch Normalization, SiLU 활성화 함수로 구성된 modified stem을 통과한다. 이후 EfficientNet-B0를 통해 ECG 파형의 특징을 단계적으로 추출한다. EfficientNet-B0는 여러 개의 Mobile Inverted Bottleneck Convolution(MBConv) 블록을 기본 구성 요소로 사용한다. MBConv는 제한된 연산 자원에서도 효율적으로 동작할 수 있도록 설계된 경량 합성곱 블록으로, 입력 정보를 확장한 뒤 필요한 특징을 추출하고 다시 압축하는 구조이다 [41]. 이를 통해 모델은 lead 축과 시간축에 따라 나타나는 ECG 파형의 형태적 특징을 점진적으로 학습한다. 최종적으로 classification head에서는 global average pooling을 적용하여 추출된 특징을 하나의 벡터로 요약하고, linear layer를 통해 Signal Logit을 산출한다. 해당 모델은 Signal-Only 성능 평가에 사용되었으며 그림 5(a)에서 확인할 수 있듯이 Hybrid Fusion 구조에서 Signal Model Branch로 활용되었다.

2. ECG 피쳐 분류 모델

1) 피쳐 셋 및 비교 모델 구성

ECG 피쳐는 원시 ECG 신호와 달리 시간축을 따라 연속적으로 배열된 파형이 아니라, 각 ECG 기록에서 산출된 수치형 측정값과 파생 변수로 구성된 피쳐 벡터이다. 따라서 본 연구에서는 피쳐 선택에 따른 성능을 확인하고, 이후 Hybrid Fusion 모델의 Feature Model Branch로 활용할 피쳐 분류 모델을 선정하고자 그룹별 피쳐 셋을 두 개의 모델로 각각 평가하였다. 피쳐 셋은 그림 4에 제시된 통계적 유의성 순위를 기준으로 그룹별 상위 N개의 피쳐를 순차적으로 선택하여 구성하였다. 구체적으로 상위 3개, 5개, 7개, 10개 피쳐, 통계적으로 유의한 피쳐 집합, 그리고 전체 피쳐 집합으로 구분하였다.

비교 모델은 KNN과 다층 퍼셉트론(multilayer perceptron, MLP) [42]을 사용하였다. KNN은 선행연구 [3]에서 ECG 피쳐 기반 뇌졸중 분류에 사용된 여러 전통적 머신러닝 모델 중 가장 높은 성능을 보인 모델이므로, 기초 비교 모델로 포함하였다. KNN의 경우 유클리드 거리를 기반으로 검증 데이터 셋을 이용해 최적의 k 값을 결정하였다. 한편 MLP는 fully connected layer를 기반으로 입력 피쳐 간의 비선형 관계를 학습할 수 있는 신경망 모델이며, 구조화된 수치형 데이터에서도 효과적으로 활용될 수 있음이 보고되어 왔다 [43]. 특히 본 연구의 피쳐 모델은 단순한 독립 분류기에 그치지 않고 이후 Hybrid Fusion 모델의 Feature Model Branch로 활용되어야 하므로, 최종 logit뿐만 아니라 중간 은닉층을 통해 은닉 표현을 산출할 수 있는 신경망 기반 모델이 필요하다. 표현 학습 관점에서 신경망의 중간 표현은 원래 입력을 분류에 유용한 표현으로 변환하는 역할을 하며 [44], 멀티모달 학습에서도 각 모달

리티를 개별 브랜치 또는 인코더를 통해 표현으로 변환한 뒤 결합하는 방식이 널리 사용된다 [45,46]. 이에 본 연구에서는 KNN과 함께 MLP를 피쳐 기반 분류 모델로 평가하였다. MLP 모델은 선택된 피쳐의 개수를 입력 차원으로 설정하였으며, 32차원과 16차원의 두 은닉층으로 구성하였다. 각 층에는 dropout(0.2)이 적용되었다.

2) ECG 피쳐 분류 모델 구조




그림 7. 피쳐 분류 모델 세부 구조

본 연구에서는 그룹별 피쳐 분류 실험 결과를 바탕으로 MLP를 분류 모델로 선정하였다. 그림 7은 피쳐 분류 모델의 세부 구조를 보여준다. 128, 128, 64, 32차원의 네 개 은닉층으로 구성되었으며, 마지막 linear layer를 통해 Feature Logit을 산출한다. 마지막 층을 제외한 각 은닉층 뒤에는 batch normalization, ReLU 활성화 함수, dropout(0.2)을 적용하였다. 해당 모델은 전체 50개 피쳐에서의 성능 평가에 사용되었으며 최적 피쳐 셋 구성을 위한 제거 실험에 사용되었다. 이후 최종적으로 구성된 최적 피쳐 셋을 입력으로 하는 Feature-Only 모델로서 단일모달 성능 평가에 활용되었다. 또한 그림 5(b)에서 확인할 수 있듯이 Hybrid Fusion 모델의 Feature Model Branch로 사용되었다.

3. 하이브리드 퓨전 멀티모달 프레임워크

1) 멀티모달 학습

멀티모달 학습은 서로 다른 형태의 데이터로부터 얻은 정보를 함께 활용하여, 단일 모달리티만으로는 충분히 포착하기 어려운 상호보완적 정보를 학습하는 방법이다 [47,48]. 의료 데이터는 영상, 생체신호, 임상 변수, 검사 결과 등 서로 다른 자료 구조를 갖는 정보로 구성되는 경우가 많으며, 이러한 이질적인 정보를 적절히 결합하면 질병 분류나 예후 예측에서 더 풍부한 표현을 학습할 수 있다 [49]. 멀티모달 학습에서 정보 결합 방식은 결합 시점과 표현 수준에 따라 raw data 수준의 결합, 피처 또는 임베딩 수준의 결합, 그리고 최종 예측값 수준의 결합으로 구분될 수 있다 [50]. Raw data 수준의 결합은 서로 다른 입력을 모델의 가장 앞단에서 직접 연결하는 방식이지만, 입력 차원과 자료 구조가 크게 다를 경우 적용이 어렵다. 반면 피처 또는 임베딩 수준의 결합은 각 모달리티를 개별 인코더를 통해 고정된 차원의 표현으로 변환한 뒤 이를 결합하는 방식으로, 모달리티별 특성을 먼저 학습하면서도 이후 단계에서 통합 표현을 학습할 수 있다는 장점이 있다. 이러한 raw data 수준의 결합과 피처 또는 임베딩 수준의 결합은 넓은 의미에서 early fusion에 해당한다. 최종 예측값 수준의 결합은 각 모달리티에서 독립적으로 산출된 예측값을 결합하는 방식으로, late fusion에 해당한다.

기존 의료 멀티모달 연구에서도 early fusion과 late fusion을 함께 포함하는 hybrid fusion 전략이 제안된 바 있다 [51]. 본 연구 역시 ECG 신호와 ECG 피처 간의 상호작용을 early fusion 단계에서 학습하고, 이를 Signal-Only 모델 및 Feature-Only 모델의 독립적인 예측과 late fusion하는 하이브리드 구조를 설계하였다. 다만 본 연구는 기본 Early Fusion 모델의 예측을 단순히 late fusion에 추가하

는 데 그치지 않고, 최종 Hybrid Fusion에 포함되는 early fusion 브랜치의 표현 학습 능력을 강화하고자 하였다. 이를 위해 기본 Early Fusion 모델에 Raw Interaction Branch를 추가하여 Interaction Early Fusion 모델을 설계하였다. Raw Interaction Branch는 ECG 피쳐 정보를 신호 입력과 결합 가능한 형태로 변환한 뒤 ECG 신호와 함께 처리함으로써, 피쳐 정보가 ECG 신호 표현 학습의 초기 단계부터 반영될 수 있도록 한다. 최종적으로 본 연구의 Hybrid Fusion 모델은 Signal-Only, Feature-Only, Interaction Early Fusion 모델의 logit을 결합하여, early fusion의 상호작용 학습 효과와 late fusion의 예측 통합 효과를 함께 활용하도록 구성하였다.

2) Early Fusion 모델

Early fusion은 서로 다른 모달리티의 정보를 모델의 초기 또는 중간 단계에서 결합하여 하나의 통합 표현을 학습하는 방식이다. 본 연구와 유사하게 ECG 신호와 구조화된 임상 피쳐를 함께 활용한 선행연구에서도, 각 입력을 개별적으로 처리하여 피쳐 벡터로 변환한 뒤 퓨전 모듈에서 결합하는 방식을 사용하였다 [13]. 이러한 선행 연구를 바탕으로 본 연구에서도 두 모달리티를 표현 수준에서 결합하는 기본 Early Fusion 모델 구조를 설계하였다. ECG 신호와 피쳐를 각각 Signal Embedding과 Feature Embedding으로 변환한 뒤 연결하여 통합 표현을 구성하였다. 신호 임베딩은 그림 6의 신호 분류 모델에서 linear layer를 거치기 전의 1280차원 벡터를 사용하였다. 그리고 선형 변환을 통해 512차원의 Signal Embedding을 생성한다. 피쳐 임베딩은 그림 7의 피쳐 분류 모델에서 두 번째 은닉층의 출력인 128차원 벡터를 사용하였다. 차원 변환 없이 그대로 Feature Embedding으로 사용하였다. 이후 512차원의 Signal Embedding과 128차원의 Feature Embedding을 연결하여 640차원의 통합 표현을 생성하고, 이를 classification head에 입력하여 최종 예측값을 산출하

였다. Classification head는 640차원의 입력을 128차원, 128차원, 32차원으로 순차적으로 변환하는 세 개의 은닉층과 최종 1차원 logit을 출력하는 선형층으로 구성된다. 각 은닉층 뒤에는 batch normalization, ReLU 활성화 함수, dropout(0.2)을 적용하였다.

3) Interaction Early Fusion 모델




그림 8. Interaction Early Fusion 모델 구조

Late Fusion은 각 단일모달 모델의 독립적인 예측을 보존한 뒤 결합하는 것을 목적으로 하는 반면, Early Fusion은 모델 내부의 표현 학습 단계에서 모달리티 간 상호작용을 반영하는 것을 목적으로 한다. 본 연구의 기본 Early Fusion 모델은 ECG 신호 임베딩과 피쳐 임베딩을 연결하여 통합 표현을 구성하였으나, 이 방식은 각 모달리티의 표현이 독립적으로 추출된 이후 결합되므로 피쳐 정보가 신호 표현 학습의 초기 단계에 직접 반영되기 어렵다. 이에 본 연구에서는 Early Fusion의 목적에 맞게 두 모달리티 간 상호작용을 보다 적극적으로 반영하기 위해, 기본 Early Fusion 모델에 Raw Interaction Branch를 추가한 Interaction Early Fusion 모델을 설계

하였다. 그림 8은 Interaction Early Fusion 모델의 전체 구조를 보여준다. Raw Interaction Branch에서는 피처를 신호 입력과 결합 가능한 형태로 변환한 뒤 ECG 신호와 함께 처리하고, self-attention을 적용하여 임베딩 생성 이전 단계에서 두 모달리티 간의 초기 상호작용을 학습한다. 이후 해당 브랜치에서 산출된 Interaction Embedding은 기존의 Signal Embedding 및 Feature Embedding과 함께 연결되어 최종 분류층의 입력으로 사용된다. 따라서 Interaction Early Fusion 모델은 기본 Early Fusion의 임베딩 수준 결합에 더해, 초기 표현 단계에서의 ECG 신호와 피처 간 상호작용을 함께 반영하는 구조이다.

의료 멀티모달 분류 연구에서는 서로 다른 모달리티에서 추출된 표현을 결합하는 intermediate fusion이 널리 사용되며, 그중 attention-based fusion은 모달리티 간 관계를 학습하기 위한 방법으로 정리되어 왔다 [52]. Self-attention은 입력 요소들 간의 관계를 반영하여 representation을 계산하는 방법으로 제안되었다 [53]. 이에 본 연구에서는 ECG 피처 정보가 ECG 신호 표현 학습 과정에 초기 단계부터 반영될 수 있도록 Raw Interaction Branch에 self-attention을 적용하였다. 그림 9는 Raw Interaction Branch의 세부 구조를 보여준다. ECG 신호는 12개 lead와 5000개의 타임 스텝으로 구성되며, 입력 형태는 12×5000 이다. 반면 ECG 피처는 N 개의 수치형 값으로 구성되어 시간축을 갖지 않는다. 따라서 먼저 N 개의 피처로 구성된 $1 \times N$ 형태의 벡터를 projection layer에 입력하여 모델 학습에 적합한 표현으로 변환한 뒤, 변환된 피처 표현을 ECG 신호의 시간 길이인 5000개 타임 스텝 전체에 동일하게 반복 확장하였다. 이를 통해 기존의 N 차원 피처 벡터는 $N \times 5000$ 형태의 시간축을 갖는 피처 행렬로 변환된다. 이후 변환된 피처 행렬을 원본 ECG 신호의 추가 채널로 결합하였다. 이때 추가되는 채널 수는 입력 피처의 개수 N 과 동일하게 설정하였다. 그 결과, Raw Interaction Branch의 입력은 시간 길이 5000을 유지하면서 채널 수가 기존 12개 lead에서 $12+N$ 개로 확장된 $(12+N) \times 5000$ 형태로 구성된다. 이렇게 결합된 입력은 1D convolution 기반 stem layer를 통과하면서 시간축 방향으로 다운샘플링




그림 9. Raw Interaction Branch 세부 구조

되어 길이 5000에서 200으로 축소된다. 다운샘플링은 이후 self-attention 연산에서 발생하는 계산량을 줄이기 위한 과정이다. 이때 각 타임 스텝은 ECG 신호와 피처가 함께 반영된 128차원의 벡터로 변환된다.

변환된 벡터는 2개의 레이어로 구성된 self-attention block을 통과한다. 각 self-attention block은 layer normalization, multi-head self-attention, feed-forward network로 구성된다. 먼저 입력 시퀀스에 layer normalization을 적용한 뒤, multi-head attention을 통해 타임 스텝 간의 관계를 학습한다. 이때 신호 정보와 피처 정보가 함께 반영된 상호작용 표현을 학습한다. 본 연구에서는

multi-head attention의 head 수를 4로 설정하여, 하나의 관점에만 의존하지 않고 여러 attention head를 통해 서로 다른 시간적 관계를 병렬적으로 학습하도록 하였다. 이후 attention 출력은 잔차 연결을 통해 원래 입력과 더해지며, 다시 layer normalization과 feed-forward network를 거친다. Feed-forward network는 128차원의 표현을 256차원으로 확장한 뒤 GELU 활성화 함수와 dropout(0.2)을 적용하고, 다시 128차원으로 축소하는 구조로 구성된다. 마지막 잔차 연결은 feed-forward network의 출력과 입력 표현을 결합하여 학습 안정성을 높인다. 최종적으로 layer normalization과 global average pooling 하여 128차원의 Interaction Embedding을 생성한다.

이후 512차원의 Signal Embedding, 128차원의 Feature Embedding, 그리고 Raw Interaction Branch에서 생성된 128차원의 Interaction Embedding을 연결하여 768차원의 결합 벡터를 생성한다. 이후 classification head는 해당 벡터를 입력으로 받아 Early Fusion Logit을 산출한다. Classification head는 768차원의 입력을 128차원, 128차원, 32차원으로 순차적으로 변환하는 세 개의 은닉층과 최종 1차원 logit을 출력하는 선형층으로 구성된다. 각 은닉층 뒤에는 batch normalization, ReLU 활성화 함수, dropout(0.2)을 적용하였다. 해당 모델은 그림 5(c)에서 확인할 수 있듯이 Hybrid Fusion 모델에서 Interaction Early Fusion Model Branch로 활용된다.

각 브랜치의 임베딩 차원을 다르게 설정한 것은 각 입력 정보의 특성과 단일모달 실험 결과를 함께 고려한 것이다. 먼저 ECG 신호 데이터는 전체 12-lead 파형을 포함하는 고차원 입력으로, 심장의 전기적 활동에 대한 풍부한 시간적·형태적 정보를 담고 있다. 또한 단일모달 실험에서도 Signal-Only 모델이 Feature-Only 모델보다 높은 성능을 보여, Signal Embedding은 상대적으로 큰 512차원으로 설정하였다. 반면, 피쳐 데이터는 ECG에서 산출된 정량적 정보를 제공하지만, 단일모달 실험에서는 Signal-Only 모델에 비해 상대적으로 낮은 성능을 보였다. 또한 Raw Interaction

Branch는 새로운 독립 모달리티를 추가하는 구조라기보다, 신호와 피쳐 간의 상호작용 정보를 보완적으로 학습하기 위한 구성 요소이다. 따라서 Feature Embedding과 Interaction Embedding은 각각 128차원으로 설정하였다. 이러한 설정은 융합 과정에서 상대적으로 예측 기여도가 낮거나 보완적 성격을 갖는 표현이 과도하게 반영되는 것을 방지하기 위한 것이다.

4) Late fusion 기반 Hybrid Fusion 모델




그림 10. Hybrid Fusion 모델 최종 예측 과정

Late fusion은 각 모달리티 또는 모델에서 산출된 예측 결과를 최종 의사결정 단계에서 결합하는 방식이다. 본 연구에서는 제안 모델과의 성능 비교를 위해 기본 Late Fusion 모델을 구성하였다. 해당 모델은 Signal-Only 모델의 Signal Logit과 Feature-Only 모델의 Feature Logit을 동일한 가중치로 평균하여 최종 예측값을 도출한다. 이러한 기본 Late Fusion 모델에 Interaction Early Fusion 모델에서 산출된 Early Fusion Logit을 추가로 결합하여 최종 예측을 수행하는 구조가 본 연구에서 제안하는 Hybrid Fusion 모델이다. 그림 10은 Hybrid Fusion 모델의 최종 예측 과정을 보여주며 전체 프레임워크에서는 그림 5(d)에 해당한다. Hybrid Fusion 모델은 Signal Model Branch와 Feature Model Branch 그리고 Interaction Early

Fusion Model Branch로 구성된다. 세 브랜치는 각각 Signal Logit, Feature Logit, Early Fusion Logit을 출력하며, Hybrid Fusion 단계에서는 세 logit을 동일한 가중치로 평균한다. 이는 각 모델이 산출한 최종 예측 정보를 의사결정 단계에서 균형 있게 결합하기 위함이다. 이후 평균된 logit에 sigmoid 함수를 적용하여 뇌졸중 발생 확률을 산출하고, 검증 데이터에서 결정된 최적 임계값을 기준으로 최종 예측 결과를 결정한다. 이러한 구조를 통해 단일모달 모델이 학습한 독립적인 예측 정보뿐만 아니라, early fusion 단계에서 학습된 신호와 피쳐 간의 상호작용 정보까지 최종 예측에 반영한다. 따라서 제안 모델은 early fusion의 상호작용 학습 효과와 late fusion의 예측 통합 효과를 함께 활용한다.

제4장 실험 결과

1. 학습 설정

1) 평가 모델 구성 및 학습 설정

본 연구에서는 ECG foundation 모델인 ECG-FM [54]과 HuBERT-ECG [55]를 비교 모델로 사용하였고, 직접 구현한 기본 Early Fusion 및 Late Fusion 모델을 baseline으로 설정하였다. ECG-FM은 대조 학습과 생성 학습을 결합한 자기지도학습 기반 모델이며, HuBERT-ECG는 마스킹 기반 자기지도학습을 활용한 모델이다. 두 모델은 모두 ECG 신호만을 입력으로 사용하는 시계열 기반 단일모달 모델로, 본 연구에서는 공개된 사전학습 가중치를 초기값으로 사용하여 본 연구 데이터 셋에 맞게 미세조정하였다. HuBERT-ECG는 실험적으로 더 안정적인 학습이 확인된 배치 크기 32와 학습률 1×10^{-5} 를 별도로 적용하였으며, 이를 제외한 모든 모델과 실험에는 동일한 학습 설정을 사용하였다. Epoch 수는 early stopping 전략에 따라 결정하였고, 검증 데이터의 loss가 5 epoch 연속으로 개선되지 않을 경우 학습을 종료 후 최소 손실값에서의 모델을 사용하였다. 공통 학습 설정으로는 학습률 1×10^{-3} , 배치 크기 64, 최적화 알고리즘 AdamW를 사용하였으며, 손실 함수는 Binary Cross-Entropy with Logits Loss (BCEWithLogitsLoss)를 사용하였고, 이는 다음과 같이 정의된다.

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i))]$$

여기서 y_i 는 실제 정답 레이블, z_i 는 모델의 logit 출력, $\sigma(\cdot)$ 는 sigmoid 함수를 의미한다. 모든 실험은 환자 단위 5-fold 교차 검증을 사용하여 수행되었으며, 각 fold의 성능을 바탕으로 평균 성과 95% 신뢰구간(confidence interval, CI)을 함께 보고하였다.

2) 평가 지표

본 연구에서는 제안된 모델의 성능을 종합적으로 검증하기 위해 분류 성능, 확률 예측의 신뢰도, 그리고 예측 결과의 해석 가능성 측면에서 평가를 수행하였다. 먼저, 전체 모델 비교를 위한 기본 평가지표로 ROC-AUC, Brier score, Accuracy, Precision, Recall, F1-score를 사용하였다. ROC-AUC는 임계값(threshold)에 영향받지 않고 모델의 전반적인 클래스 판별 능력을 평가하는 지표이며 AUC로 표기하였다. Brier score는 예측 확률과 실제 레이블 간의 평균 제곱 오차를 나타내는 확률 보정 관련 지표이다. 모델이 산출한 확률값이 실제 발생 가능성을 얼마나 신뢰성 있게 반영하는지를 확인하기 위한 지표로 활용되며 값이 낮을수록 예측 확률이 실제 결과와 더 잘 일치함을 의미한다. 임계값 기반 지표인 Accuracy, Precision, Recall, F1-score는 검증 데이터 셋에서 Youden Index [56]를 기준으로 도출한 최적 임계값을 테스트 셋에 적용하여 산출하였다. Youden Index는 $J = \text{Sensitivity} + \text{Specificity} - 1$ 로 정의되며, 본 연구에서는 J 가 최대가 되는 임계값을 최적 임계값으로 설정하였다. 모든 평가 결과는 5-fold 평균값으로 제시하였으며, 비율 기반 지표는 백분율(%)로, 확률 및 점수 기반 지표는 0과 1 사이의 소수값으로 표기하였다.

추가적으로, Hybrid Fusion 모델에 대해서는 임상적 적용 가능성과 예측 결과의 해석 가능성을 구체적으로 확인하기 위한 심층 분석을 수행하였다. 먼저, 모델이 산출한 확률값의 신뢰도를 시각적으로 검증하기 위해 확률 보정 곡선(calibration curve)

을 분석하였다. Calibration curve는 모델이 예측한 위험 확률과 실제 양성 발생 비율 간의 일치 정도를 시각화한다. 또한, 고위험군 누락을 최소화해야 하는 뇌졸중 진단의 임상적 특성을 고려하여, 민감도 90% 기준에서의 위양성률(false positive rate, FPR)을 추가적인 임상적 비교 지표로 평가하였다. 마지막으로, 최종 제안 모델이 예측을 도출한 근거를 확인하기 위해 Grad-CAM [57], SHapley Additive exPlanations(SHAP) [58], 그리고 attention 히트맵 분석을 통한 정성적 평가를 수행하였다. Grad-CAM은 신호에서 모델이 예측을 위해 주목한 영역을 시각화하기 위해 사용하였고, SHAP는 입력 피처가 예측에 미친 기여도를 분석하기 위해 사용하였다. 또한 attention 히트맵은 모델이 신호와 피처 정보가 결합된 상호작용 표현에서 중요하게 반영한 구간을 확인하기 위해 활용하였다.

2. 단일모달 모델 성능 평가

1) ECG 신호 기반 모델의 분류 성능

표 2. ECG 신호 기반 모델의 성능 비교

Model	Accuracy	Precision	Recall	F1-score	AUC	Brier
1D InceptionTime	67.5 (63.7-71.2)	71.6 (69.7-73.6)	61.5 (46.6-76.3)	65.6 (58.2-72.9)	0.759 (0.730-0.788)	0.201 (0.187-0.215)
1D ResNet-18, based on [12]	70.7 (68.4-73.1)	69.9 (64.0-75.7)	77.4 (68.5-86.3)	73.1 (71.5-74.6)	0.774 (0.752-0.796)	0.195 (0.184-0.206)
2D ResNet-18	72.6 (69.3-75.9)	71.2 (66.5-76.0)	79.1 (74.1-84.1)	74.8 (72.7-77.0)	0.793 (0.768-0.819)	0.187 (0.174-0.200)
2D EfficientNet-B0	73.0 (69.5-76.5)	73.0 (69.3-76.7)	76.0 (64.1-87.9)	74.1 (69.0-79.3)	0.798 (0.768-0.827)	0.186 (0.169-0.204)

표 2에 제시된 ECG 신호 기반 모델별 분류 결과를 보면, 전반적으로 ImageNet으로 사전학습된 2D 모델이 1D 모델보다 우수한 성능을 보였다. 특히 EfficientNet-B0

는 가장 높은 AUC(0.798)와 가장 낮은 Brier score(0.186)를 기록하여 전체적으로 가장 우수한 성능을 나타냈다. 반면, 2D ResNet-18은 가장 높은 Recall(79.1%)과 F1-score(74.8%)를 보여 민감도 및 균형 성능 측면에서 강점을 보였다. 이러한 결과는 본 실험 설정에서 사전학습된 2D CNN 기반 모델이 1D 기반 모델보다 뇌졸중 ECG 신호 분류에 더 효과적일 수 있음을 보여준다. 즉, ECG 신호 분류에서는 시간적 변화를 중심으로 학습하는 1D 기반 접근보다, lead 간의 관계와 시간에 따른 파형 변화를 함께 반영하는 2D 기반 접근이 더 효과적일 수 있음을 시사한다. 본 연구에서는 단일 지표보다 전반적인 분류 성능과 확률 예측의 안정성을 함께 고려하였기 때문에, 가장 높은 AUC와 가장 낮은 Brier score를 보인 EfficientNet-B0를 Signal-Only 모델로 선정하였다.

2) ECG 피쳐 기반 모델의 분류 성능

그룹별 유의성 순위를 기준으로 피쳐 셋을 구성하고, KNN과 MLP의 성능을 비교하였다. KNN 및 MLP의 상세 성능은 부록 2의 표 2-1과 표 2-2에 제시하였다. 전반적으로 MLP가 KNN보다 우수한 성능을 보였다. KNN은 거리 기반 분류기로서 샘플 간 거리 정보에 의존하는 반면, MLP는 비선형 변환을 통해 피쳐 간 복합적인 패턴을 학습할 수 있기 때문으로 해석된다. 따라서 피쳐 분류 모델로 MLP를 사용하였다. 또한 Extracted 피쳐 셋보다 MUSE 피쳐 셋에서 더 높은 성능이 관찰되었다. KNN과 MLP 모두 MUSE All features에서 가장 높은 AUC를 기록하였으며, MLP의 경우 AUC 0.702와 가장 낮은 Brier score 0.218을 보여 전체적으로 가장 우수한 성능을 나타냈다. 이는 MUSE 그룹 피쳐가 장비에서 직접 산출된 파형 간격, 지속시간, 시작점 및 종료점과 같은 기준점 기반 변수들로 구성되어 ECG의 형태 및 시간적 특성을 비교적 일관되게 반영한 반면, Extracted 피쳐는 신호 전처리 및 피쳐 추출 과정에 따라 변동성이 커질 수 있기 때문으로 해석된다. 결과적으로 MLP 모델을 이용한 피

표 3. 전체 50개 피처의 유의성 순위 기반 피처 셋별 MLP 성능 비교

Feature set	Num	Accuracy	Precision	Recall	F1-score	AUC	Brier
Top-10	10	60.5 (58.7-62.4)	61.6 (59.8-63.5)	61.8 (56.3-67.3)	61.7 (58.7-64.6)	0.648 (0.631-0.665)	0.231 (0.226-0.237)
Top-20	20	62.4 (60.8-64.0)	64.2 (56.8-71.5)	65.9 (46.8-85.1)	63.6 (55.4-71.7)	0.681 (0.658-0.704)	0.224 (0.217-0.231)
p<0.05	30	63.0 (62.1-63.9)	65.9 (63.1-68.6)	59.0 (50.0-68.1)	62.0 (57.8-66.1)	0.691 (0.681-0.702)	0.222 (0.218-0.226)
MUSE All + Extracted p<0.05	39	64.8 (62.3-67.2)	66.6 (64.1-69.0)	63.3 (59.6-67.1)	64.9 (61.9-67.8)	0.697 (0.681-0.712)	0.220 (0.215-0.225)
All	50	64.0 (61.0-67.1)	65.1 (59.4-70.7)	67.7 (56.9-78.5)	65.8 (63.7-68.0)	0.708 (0.673-0.744)	0.217 (0.206-0.228)

처 셋별 성능 평가 결과, Extracted 그룹에서는 $p<0.05$ 기준 피처 셋이 모든 평가 지표에서 가장 우수한 성능을 보였으며, MUSE 그룹에서는 전체 피처를 사용했을 때 전반적으로 가장 좋은 성능을 보였다. 이에 따라 본 연구에서는 각 그룹에서 가장 우수한 성능을 보인 두 피처 셋, 즉 MUSE All 피처 셋과 Extracted $p<0.05$ 피처 셋을 결합하여 추가적인 성능 평가를 수행하였다. 또한 두 그룹의 모든 피처를 포함한 전체 50개 피처 셋에 대해서도 유의성 순위 기반 성능을 함께 확인하였다.

표 3은 전체 50개 피처를 대상으로 유의성 순위 기반 피처 셋 구성에 따른 피처 분류 모델의 성능 변화를 보여준다. 입력 피처 수가 증가함에 따라 AUC는 전반적으로 향상되는 경향을 보였으며, All 피처 셋에서 가장 높은 AUC 0.708과 가장 낮은 Brier score 0.217을 기록하였다. 또한 Recall과 F1-score도 All 피처 셋에서 가장 우수한 성능을 나타냈다. 이러한 결과는 통계적으로 유의하거나 성능이 더 좋은 그룹의 피처만을 제한적으로 사용하는 것보다 더 많은 피처를 활용하는 것이 성능에 유리할 수 있음을 보여준다. 그러나 Accuracy와 Precision은 MUSE All + EXTRACTED $p<0.05$ 피처 셋에서 가장 높았다. 이러한 결과는 피처 수의 증가가 모든 평가 지표를 일관되게 개선하지는 않음을 나타낸다. 이는 두 그룹 간 피처가 일부가 중복되거나 상대적으로 불안정한 정보를 포함하여 오히려 노이즈로 작용했을 가능성이 있기 때문으

로 해석된다. 이러한 결과를 정밀하게 해석하고 안정적인 피쳐 셋 구성을 위해 피쳐 분석과 제거 실험을 수행하였다.

3. ECG 피쳐 분석 및 최종 구성

1) 피쳐 사용 적합성 검토

최적 피쳐 셋 구성에 앞서, MI의 적용 타당성, HRV 관련 피쳐의 신뢰성, MUSE와 Extracted 그룹 간의 중복 피쳐 존재 여부를 검토하였다. 상세한 피쳐 분석 결과는 부록 3에 제시하였다. 결측 패턴 분석 결과 POnset, POffset, PRInterval, PAxis로 구성된 4개의 P-wave 관련 변수의 결측은 레이블 또는 나이와 관련성을 보여 단순한 무작위 결측이 아니라 질환 또는 연령과 관련된 정보를 포함할 가능성이 확인되었다. 반면 QTcFrederica의 결측은 뇌졸중군에서만 관찰되었으나, 수집 연도 및 측정 장비와의 관련성이 더 크게 나타나 수집 환경의 영향을 반영한 결과인 것으로 확인되었다. 이에 따라 QTcFrederica MI 변수는 후속 실험에서 제외하였고, 49개 피쳐 셋을 제거 실험을 위한 baseline으로 설정하였다. 반면 LF, HF, VLF, LF/HF와 같은 HRV 관련 피쳐는 10초 길이의 ECG에서 안정적으로 추정되기 어렵고, 결측 분석 결과 레이블, 나이, 성별, 수집 연도 및 측정 장비와 유의한 관련성을 보이지 않아, 질환 특이적 결측 패턴이라기보다 기술적 추출 과정에서 발생한 결측일 가능성이 높은 것으로 해석하였다. 따라서 HRV 관련 피쳐 4개와 해당 피쳐 각각의 MI를 포함하는 총 8개의 변수를 HRV set으로 설정하고 이 셋의 포함 여부가 실제 분류 성능에 어떤 영향을 미치는지 확인하기 위한 제거 실험을 수행하였다. 결측 관련 분석 결과는 부록 3의 표 3-1, 3-2에 제시하였다.

MUSE 그룹과 Extracted 그룹 간 중복 피쳐를 확인하기 위해 상관분석을 수행한

결과, Extracted 그룹의 2개 피처와 MUSE 그룹의 4개 피처에서 높은 상관관계가 관찰되었다. 구체적으로, Extracted 그룹의 HR은 MUSE 그룹의 VentricularRate 및 QRSCount와 높은 양의 상관관계를 보였으며, GlobalRR 및 PharmaRRinterval과는 높은 음의 상관관계를 나타냈다. 또한 Extracted 그룹의 RR-I는 GlobalRR 및 PharmaRRinterval과 높은 양의 상관관계를 보인 반면, VentricularRate 및 QRSCount와는 높은 음의 상관관계를 보였다. 이는 두 그룹의 일부 피처가 심박수 및 RR interval과 관련된 유사한 정보를 중복적으로 반영하고 있음을 시사한다. 다만 개념적으로 유사한 모든 변수가 높은 상관관계를 보인 것은 아니었으며, 이는 두 그룹 간의 계산 방식의 차이로 인해 각 피처가 완전히 동일한 정보를 제공하지는 않을 수 있음을 의미한다. 자세한 결과는 부록 3의 표 3-3에 제시하였다. 따라서 이러한 중복 가능성이 실제 분류 성능에 미치는 영향을 확인하기 위해 그룹 간 중복 피처 제거 실험을 수행하였다.

2) 최종 피처 구성 선정 실험

최종 피처 구성을 결정하기 위해 MI, HRV set, 그리고 중복 피처를 중심으로 피처 제거 실험을 수행하였다. 표 4는 기준 피처 셋에서 특정 피처 그룹을 제외했을 때 분류 성능이 어떻게 변화했는지를 보여준다. Baseline은 QTcFrederica MI를 제외한 49개의 피처 셋으로 설정하였으며, 이때 AUC는 0.701이었다. MI로만 구성된 Missing Only 세팅은 AUC 0.514로 크게 낮은 성능을 보였으며, 이는 모델이 결측 패턴에 의존하여 학습하지 않았음을 의미한다. 반면, all MI를 제거한 경우 AUC는 0.709로 baseline보다 향상되어, 결측 지표를 포함하는 것이 항상 성능 향상으로 이어지는 않음을 확인하였다. HRV set 제거 시 AUC가 0.718로 가장 높게 나타나, HRV 관련 피처가 분류 성능을 저하시킬 수 있음을 확인하였다. 반면 P-wave 관련 피처의 MI를 제거하면 성능 하락이 나타났고, all MI 제거와 HRV set 제거를 함께

표 4. 피쳐 그룹별 제거 실험 결과

Category	Ablation Setting	Accuracy	Precision	Recall	F1-score	AUC	Brier
Baseline	No Exclusion	64.0	64.2	69.3	66.2	0.701	0.220
		(63.0-65.0)	(60.9-67.5)	(57.8-80.8)	(62.5-70.0)	(0.686-0.715)	(0.214-0.226)
MI	Missing Only	50.6	64.0	17.3	24.6	0.514	0.248
		(48.9-52.3)	(43.8-84.2)	(3.1-31.5)	(7.5-41.7)	(0.473-0.556)	(0.244-0.252)
	w/o P-wave MI	64.0	64.2	68.9	66.3	0.694	0.223
		(60.5-67.5)	(59.7-68.8)	(62.4-75.5)	(63.7-68.9)	(0.667-0.720)	(0.212-0.234)
	w/o HRV MI	65.2	64.0	75.1	69.0	0.706	0.218
		(62.4-68.1)	(60.5-67.5)	(69.4-80.9)	(67.7-70.2)	(0.688-0.724)	(0.212-0.224)
HRV	w/o all MI	65.0	65.1	70.6	67.2	0.709	0.218
		(64.0-66.0)	(61.4-68.9)	(56.6-84.6)	(62.4-72.0)	(0.695-0.724)	(0.212-0.223)
	w/o HRV set	64.9	64.8	71.1	67.5	0.718	0.215
		(62.0-67.9)	(60.1-69.5)	(62.8-79.5)	(65.4-69.7)	(0.689-0.747)	(0.204-0.225)
Overlap	w/o all MI & HRV set	64.8	64.5	71.2	67.5	0.705	0.219
		(61.8-67.8)	(60.2-68.9)	(64.4-78.1)	(65.0-70.1)	(0.689-0.720)	(0.212-0.226)
	w/o MUSE overlap	65.5	64.2	75.7	69.3	0.704	0.220
		(62.5-68.4)	(60.5-67.9)	(67.9-83.4)	(67.2-71.3)	(0.682-0.726)	(0.212-0.227)
Combined	w/o EXT overlap	64.7	66.0	66.5	65.7	0.697	0.221
		(61.7-67.7)	(61.4-70.5)	(54.6-78.5)	(60.7-70.8)	(0.673-0.721)	(0.213-0.229)
	w/o all overlap	64.1	65.4	65.0	65.0	0.702	0.220
		(62.4-65.7)	(61.3-69.6)	(58.9-71.1)	(63.5-66.6)	(0.680-0.724)	(0.213-0.227)
	w/o HRV set & w/o MUSE overlap	65.3	66.7	65.5	66.0	0.716	0.216
		(64.1-66.6)	(64.8-68.6)	(60.6-70.4)	(64.1-67.9)	(0.698-0.735)	(0.208-0.223)

적용한 경우에도 HRV set만 제거했을 때보다 AUC가 낮았다. 이는 HRV set은 노이즈로 작용했을 가능성이 있는 반면, P-wave 관련 MI는 분류 성능에 일부 기여했을 가능성을 보여준다.

중복 피쳐 제거 비교에서는 MUSE overlap 제거 및 all overlap 제거 시 각각 AUC 0.704와 0.702를 보여 baseline보다 소폭 높은 성능을 나타냈다. 이는 일부 중복 변수의 정리가 성능 유지 또는 경미한 개선에 기여할 수 있음을 의미한다. 그러나 가장 높은 성능을 보였던 HRV set 제거와 MUSE overlap 제거를 함께 적용한 경우에는 AUC가 0.716으로 여전히 baseline보다 높았지만, HRV set만 제거했을 때의 성능에는 미치지 못하였다. 이는 중복 변수 제거가 일정 부분 유효하더라도, 모든 상

황에서 overlap 제거가 추가적인 성능 향상으로 이어지는 것은 아님을 보여준다. 결과적으로, HRV set만 제거한 구성이 AUC, Brier score 측면에서 가장 우수한 성능을 보였다. 따라서 본 연구에서는 HRV set을 제외한 41개의 피쳐 셋을 Feature-Only 모델 및 멀티모달 모델의 입력으로 사용하였다.

4. 성능 비교 및 모델 해석

1) 단일모달 및 멀티모달 모델 성능 비교

표 5. 단일모달 및 멀티모달 모델 성능 비교

Group	Model	Accuracy	Precision	Recall	F1-score	AUC	Brier	FPR at Sens=90*
Unimodal	Feature-Only	64.9 (62.0-67.9)	64.8 (60.1-69.5)	71.1 (62.8-79.5)	67.5 (65.4-69.7)	0.718 (0.689-0.747)	0.215 (0.204-0.225)	68.3 (61.2-75.4)
	Signal-Only	73.0 (69.5-76.5)	73.0 (69.3-76.7)	76.0 (64.1-87.9)	74.1 (69.0-79.3)	0.798 (0.768-0.827)	0.186 (0.169-0.204)	52.7 (45.9-59.6)
Foundation	ECG-FM [54]	65.4 (61.7-69.2)	65.0 (61.6-68.4)	71.5 (57.7-85.3)	67.7 (61.1-74.3)	0.717 (0.686-0.747)	0.215 (0.204-0.226)	66.3 (58.6-74.0)
	HuBERT-ECG [55]	67.5 (65.4-69.5)	68.9 (62.8-75.0)	69.8 (51.7-87.8)	68.3 (62.0-74.6)	0.761 (0.726-0.795)	0.199 (0.185-0.212)	58.1 (52.9-63.3)
Baselines	Early Fusion	71.8 (69.4-74.2)	71.9 (66.7-77.1)	75.3 (64.7-85.9)	73.2 (70.0-76.3)	0.810 (0.770-0.849)	0.180 (0.164-0.196)	48.3 (41.7-54.9)
	Late Fusion	73.3 (70.5-76.1)	71.2 (66.0-76.5)	81.9 (75.0-88.8)	75.9 (74.5-77.4)	0.818 (0.789-0.847)	0.176 (0.163-0.190)	47.2 (40.6-53.8)
Ours	Interaction	73.7	72.1	80.2	75.8	0.815	0.179	47.1
	Early Fusion	(71.7-75.7)	(68.8-75.4)	(74.7-85.8)	(74.3-77.4)	(0.789-0.841)	(0.168-0.189)	(43.7-50.5)
	Hybrid Fusion	75.5 (73.3-77.7)	73.5 (69.3-77.7)	82.7 (74.3-91.1)	77.6 (75.1-80.1)	0.832 (0.809-0.856)	0.169 (0.157-0.181)	45.2 (37.4-53.1)

* FPR at Sens=90은 민감도 90% 기준의 별도 임계값에서 산출하였다.

표 5에 단일모달 모델, 사전 학습된 foundation 모델, baseline 멀티모달 모델,

그리고 본 연구에서 제안한 모델들의 분류 성능을 제시하였다. 단일모달 모델 중에서는 Signal-Only 모델이 AUC 0.798, Brier score 0.186을 기록하여 가장 우수한 성능을 보였다. 반면 Feature-Only 모델은 AUC 0.718, Brier score 0.215로 상대적으로 낮은 성능을 기록했다. ECG-FM과 HuBERT-ECG 역시 각각 AUC 0.717, 0.761에 그쳐 Signal-Only 모델 성능을 넘지 못했다. 이는 대규모 심전도 데이터로 사전 학습된 파운데이션 모델보다, ImageNet으로 사전 학습된 2D CNN 계열의 모델이 뇌졸중 환자의 ECG 신호의 이상 패턴을 변별력 있게 추출하는 데 오히려 더 효과적이었음을 시사한다.




그림 11. 단일모달 및 멀티모달 모델 성능 비교

그림 11은 단일모달 모델 대비 Hybrid Fusion 멀티모달 모델의 성능 향상을 시각화한 결과로, 각 수치는 Signal-Only 모델을 기준으로 한 성능 향상 정도를 나타낸다. Hybrid Fusion 모델은 Signal-Only 모델과 비교 시 Recall 6.7%p, F1-score 3.5%p, AUC 0.034가 증가하였으며, 비교 모델 중 모든 지표에서 가장 우수한 성능을 기록하였다. 또한 높은 민감도를 요구하는 FPR at Sensitivity 90% 지표에서




그림 12. Signal-Only 모델과 Hybrid Fusion 모델의 ROC 곡선 비교

Hybrid Fusion은 45.2%로 가장 낮은 FPR을 보였으며, Signal-Only 대비 위양성률을 7.5%p 낮췄다. 이러한 결과는 ECG 신호 정보와 피쳐 정보를 함께 활용하는 멀티모달 접근이 효과적이며, early fusion과 late fusion을 결합한 Hybrid Fusion 구조가 두 정보를 효과적으로 통합함으로써 뇌졸중 분류 성능을 향상시킬 수 있음을 보여준다. 또한 그림 12에서 볼 수 있듯이, 본 모델은 평균 0.832의 높은 AUC를 달성하였으며 각 fold의 ROC 곡선이 Signal-Only보다 밀집되어 나타났다. 이는 모델이 특정 데이터 분할에 과도하게 의존하지 않고, 서로 다른 테스트 분할에서도 비교적 일관된 성능을 유지했음을 시사한다.

Baseline 멀티모달 모델들과의 비교에서도 유의미한 결과가 확인되었다. 기본 Early Fusion은 AUC 0.810을 기록한 반면, 본 연구에서 제안한 Interaction Early Fusion 모델은 AUC 0.815를 기록하였고 그 외 모든 지표에서 개선된 성능을 보였다. 이는 Raw Interaction Branch가 신호와 피쳐의 초기 상호작용 정보를 반영함으로써 성능 향상에 기여했음을 보여준다. Hybrid Fusion 모델은 기본 Late Fusion 모델 대비 모든 지표에서 개선되었으며 특히 Accuracy는 2.2%p, AUC는 0.014 향




그림 13. Hybrid Fusion 모델의 Calibration Curve

상되었다. 비록 Interaction Early Fusion 단독 모델의 성능은 기본 Late Fusion 모델보다 다소 낮았으나, Interaction Early Fusion Model Branch가 Hybrid Fusion 모델의 성능 향상에 기여하여 Late Fusion 모델보다 높은 성능을 기록하였다.

Hybrid Fusion 모델의 예측 확률이 실제 결과와 잘 일치하는지 확인하기 위해 확률 보정 곡선을 분석하였다. 그림 13의 calibration curve에서 x축은 모델이 산출한 평균 예측 확률을, y축은 해당 확률 구간에서 실제 뇌졸중에 해당하는 비율을 의미한다. 곡선이 대각선 기준선에 가까울수록 모델의 예측 확률이 실제 결과와 잘 일치한다고 해석할 수 있다. 본 연구에서는 5-fold 테스트 셋의 예측 결과를 통합하여 calibration curve를 생성하였으며, 이는 각 확률 구간에서 실제 양성 비율을 보다 안정적으로 확인하기 위함이다. Hybrid Fusion 모델의 평균 Brier score는 0.169로 비교 모델들보다 낮게 나타났으며, 이는 제안 모델이 예측 확률의 신뢰도 측면에서도 안정적인 성능을 보였음을 보여준다.

2) Grad-CAM 분석




그림 14. 예측 결과별 Grad-CAM 히트맵 Lead II 샘플 비교

Interaction Early Fusion 모델의 Signal Encoder에 Grad-CAM을 적용하여 분석을 수행하였다. Grad-CAM 히트맵은 색이 따뜻할수록 해당 구간이 예측에 더 크게 기여했음을, 차가운 색일수록 기여도가 낮았음을 의미한다. 그림 14는 True Positive(TP), True Negative(TN), False Positive(FP), False Negative(FN)의 네 가지 예측 결과 유형별 대표 샘플에 대한 Lead II의 Grad-CAM 히트맵을 나타낸다. TP 사례에서 활성화는 주로 QRS군이 나타나는 구간에 집중되어 관찰되었다. 이러한 결과는 모델이 양성 사례를 예측할 때 심실 탈분극⁴⁾과 관련된 주요 파형 정보를 중요하게 활용했을 가능성을 시사한다. 반면, TN 히트맵은 T파의 종료 시점부터 P파까지의 구간에서 가장 활성화되어 있고 전체적으로도 넓고 연속적인 활성화 분포를 나타낸다. 이는 모델이 TN 사례에서 전반적인 리듬의 규칙성과 ECG 파형 정보를 종합적으로 활용했을 가능성을 시사한다. 오분류된 사례의 히트맵은 모델의 한계를 보여준다. 심전도 파형을 살펴보면, FP 사례는 TP 사례와 형태적으로 유사하고 FN 사례는 TN 사례와 유사한 형태를 보인다. 이러한 파형의 외형적 유사성으로 인해 모델이

4) 심실 탈분극은 심실 근육이 전기적으로 활성화되어 수축을 시작하는 과정으로, ECG에서는 주로 QRS complex에 반영된다.

뇌졸중 환자의 ECG를 명확히 구분하는 데 어려움을 겪었을 가능성이 있다. 실제로 오분류 사례의 히트맵에서 활성화 패턴이 거의 관찰되지 않았다. 이는 뇌졸중과 비뇌졸중 간의 ECG 형태가 비슷한 양상을 보일 수 있으며, ECG 신호의 파형 정보만으로 두 군을 안정적으로 구별하는 데 한계가 있음을 의미한다.

3) SHAP 분석




그림 15. SHAP 기반 피처 중요도




그림 16. SHAP Beeswarm Plot

Interaction Early Fusion 모델의 Feature Encoder에 대해 SHAP 분석을 수행하였다. 그림 15는 모델이 예측을 수행하는 과정에서 각 피처가 예측 결과에 얼마나

기여했는지를 나타내는 피쳐 중요도를 보여준다. 5개 fold 각각에서 산출한 평균 SHAP 절대값을 다시 fold 간 평균하는 방식으로 계산하였다. 상위 5개 주요 피쳐는 QTcFrederica, TOffset, QTCorrected, QTInterval, QTc로 나타났다. 이는 뇌졸중 예측에 있어 QT 및 T파 관련 지표들이 모델의 의사결정에 가장 핵심적인 역할을 수행함을 보여준다. 그 뒤를 이어 POnset, PAxis와 같은 심방 탈분극⁵⁾ 관련 지표와 Extracted 그룹의 QRS 피쳐가 높은 중요도를 기록하였다. 반면, MUSE 그룹의 QRSDuration은 하위권에 위치하였으며, 이는 두 피쳐가 모두 QRS 지속시간과 관련되어 있음에도 산출 방식의 차이에 따라 모델 내 중요도가 다르게 나타날 수 있음을 보여준다. 또한 임상변수인 Gender가 상위권에 위치하였는데, 이는 QT 간격을 포함한 일부 ECG 피쳐가 성별에 따른 차이와 관련될 수 있음을 시사한다.

그림 16은 SHAP beeswarm plot을 통해 각 피쳐의 값이 모델 예측에 미친 영향의 방향성과 분포를 보여준다. 각 fold의 테스트 세트의 샘플에서 계산된 SHAP 값을 모두 통합하여 시각화하였다. x축의 SHAP value는 예측 기여 방향과 크기를 의미하며, 양의 값은 뇌졸중군 예측에, 음의 값은 비뇌졸중군 예측에 기여함을 나타낸다. 각 점은 개별 샘플을 의미하고, 색상은 피쳐값의 크기를 나타내며 빨간색은 높은 값, 파란색은 낮은 값을 의미한다. 최상위 중요도를 갖는 QT 관련 피쳐들은 피쳐 값이 낮을 때 양의 SHAP 값 방향으로 꼬리가 길게 분포하며, 값이 높을 때는 음의 방향으로 군집하는 패턴을 보여준다. 대조적으로 POnset, TAxis, QOffset 등의 변수는 수치가 높을수록 양의 SHAP 값을 가지며 상반된 특성을 보여주었다. 또한, POnset_missing과 같은 MI가 전체 41개 변수 중 상위 15위의 비교적 높은 기여도를 보였다. 이는 특정 피쳐의 결측 자체가 단순한 기록 누락이 아니라 심방세동⁶⁾ 등 유의미한 임상적 신호와 연관될 가능성을 시사한다. 결론적으로 이러한 SHAP 분석

5) 심방 탈분극은 심방 근육이 전기적으로 활성화되어 수축을 시작하는 과정으로, ECG에서는 주로 P-wave에 반영된다.

6) 심방세동은 심방의 전기적 활동이 불규칙해지는 부정맥으로, ECG에서는 불규칙한 RR 간격과 P-wave 소실이 특징적으로 관찰된다.

결과는 뇌졸중 환자에서 QTc 및 T파 변화와 같은 심전도 이상이 관찰된다는 기존 임상 연구 결과와 맥락을 같이 한다. 이러한 결과는 피쳐 브랜치가 뇌졸중과 관련된 ECG 특성을 예측에 반영하는 것으로 해석할 수 있다.

4) Raw Interaction Branch 분석




그림 17. Raw Interaction Branch의 self-attention 히트맵

그림 17은 예측 그룹별 대표 샘플에 대해, Interaction Early Fusion 모델의 Raw Interaction Branch에서 생성된 token들 간의 self-attention 관계를 보여준다. 가로축은 key token, 세로축은 query token을 나타내며, 색의 강도가 높을수록 특정 query token이 해당 key token을 더 강하게 참고했음을 의미한다. 여기서 token은 ECG 신호와 피쳐가 결합된 후 convolutional encoding을 통해 압축된 타

임 스텝별 특징 벡터를 의미한다. 이를 통해 모델이 token 간 관계를 어떻게 반영하는지 시각적으로 확인할 수 있다. 모든 그룹에서 가로·세로 방향으로 반복되는 모양의 패턴과 격자형 구조가 공통적으로 관찰된다. 구체적으로 TN에서는 규칙적인 격자 구조가 두드러진 반면, TP에서는 상대적으로 더 복잡적이고 일정하지 않은 attention 패턴이 나타났다. 이러한 경향은 비뇌졸중 환자의 ECG에 비해 뇌졸중 환자의 ECG에서 token 간 상호작용이 보다 불규칙하고 복잡한 양상으로 나타날 수 있음을 시사한다. 또한 FP는 TP와, FN은 TN과 유사한 패턴을 보였는데, 이는 일부 뇌졸중 환자의 ECG에서 비뇌졸중 환자와 명확히 구분되는 패턴이 나타나지 않을 수 있으며, 동시에 비뇌졸중군의 ECG에도 다른 질병으로 인한 불안정한 패턴이 포함되었을 가능성을 시사한다. 다만 전체적으로 attention의 대비가 뚜렷하지 않고 대부분의 영역이 저강도 반응으로 구성되어 있었다. 따라서 Raw Interaction Branch는 성능 향상의 주요 요인이라기보다는, ECG 신호와 피처가 결합된 표현에서 token 간 참조 관계를 반영하여 전체 모델의 예측을 보조한 것으로 해석된다.

제5장 절제 실험 및 검증 분석

본 장에서는 제안한 Hybrid Fusion 모델의 구조적 타당성과 일반화 가능성을 확인하기 위해 수행한 절제 실험 및 검증 분석 결과를 해석한다. 세부 결과 표는 부록에 제시하였으며, 부록 4에는 임베딩 크기 구성 검증, Raw Interaction Branch의 영향, 임계값 설정 전략에 따른 성능을 포함한 절제 실험 결과를 제시하였다. 부록 5에는 Signal-Only 모델과 Hybrid Fusion 모델 간 통계적 비교, 성별 및 연령별 하위그룹 분석, temporal holdout 평가를 포함한 일반화 및 통계 분석 결과를 제시하였다.

1. 절제 실험 결과

임베딩 크기 구성 실험에서는 Signal Embedding은 512차원을 부여하고, Feature Embedding과 Interaction Embedding에는 128차원을 부여한 차등 구조의 타당성을 확인하였다. Interaction Early Fusion 모델에서는 동일 임베딩 설정(256, 256, 256)과 제안 설정(512, 128, 128) 간 성능 차이가 크지 않았으나, Hybrid Fusion 모델에서는 제안한 차등 구조가 Accuracy, F1-score, AUC, Brier score 전반에서 더 우수한 성능을 보였다. 특히 동일 임베딩 설정에서는 AUC가 0.832에서 0.802로 감소하고, Brier score가 0.169에서 0.199로 증가하여 분류 성능과 예측 확률의 신뢰도가 모두 저하되었다. 이는 차등 임베딩 구성이 Hybrid Fusion 모델에 더 적합함을 보여준다. 세부 결과는 부록 4의 표 4-1에 제시하였다.

Raw Interaction Branch의 기여를 평가하기 위해, 기본 Early Fusion 모델을

적용한 Hybrid Fusion 모델과 제안한 Hybrid Fusion 모델의 성능을 비교하였다. 기본 Early Fusion 모델을 적용했을 때는 Accuracy와 Precision이 더 높았지만, Interaction Early Fusion을 적용했을 때는 Recall, F1-score, AUC, Brier score에서 개선을 보였다. 특히 Recall이 80.2%에서 82.7%로 향상되어, Raw Interaction Branch가 뇌졸중 환자 탐지 민감도를 높이는 데 기여함을 확인하였다. 따라서 Raw Interaction Branch는 민감도 중심의 예측을 보완하는 구성 요소로 해석할 수 있다. 세부 결과는 부록 4의 표 4-2에 제시하였다.

임계값 설정에 따른 성능 변화를 비교한 결과, 전체적으로 임계값이 낮아질수록 Recall은 증가하는 반면 Precision은 감소하고 FPR은 증가하는 trade-off가 나타났다. Youden index 기반 임계값은 Recall을 82.7%까지 향상시키고 F1-score는 77.6%를 유지하여, 민감도와 특이도의 균형을 고려한 주요 평가 기준으로 적절하였다. 또한 F1-best 임계값은 가장 높은 F1-score 78.5%와 높은 Recall 87.8%를 보여, 성능 측면에서 의미 있는 결과를 보였다. 반면 Sensitivity 90% 기준 임계값은 Recall을 90.5%까지 높여 고위험 환자 누락을 줄이는 데 유리하였으나, FPR도 45.2%로 가장 높게 나타났다. 이러한 결과는 임상적 적용 목적에 따라 임계값을 조정함으로써, 고위험 환자 선별을 우선하거나 오분류를 줄이는 방향으로 모델을 유연하게 활용할 수 있음을 시사한다. 세부 결과는 부록 4의 표 4-3에 제시하였다.

2. 일반화 및 통계 분석

Hybrid Fusion 모델의 성능 향상이 Signal-Only 모델 대비 통계적으로 유의한지 확인하기 위해, AUC 차이는 DeLong test로 검정하였고 [59], Accuracy, Precision, Recall, F1-score, Brier score의 차이는 bootstrap 검정으로 비교하였다 [60]. 이때 pooled AUC는 fold별 AUC의 평균이 아니라, 각 fold 테스트 셋의 예측 결과를 통

합한 뒤 전체 테스트 예측을 기준으로 산출한 AUC를 의미한다. 분석 결과, Hybrid Fusion 모델은 Signal-Only 모델보다 pooled AUC가 0.036 높았으며, DeLong test 결과 해당 차이는 통계적으로 유의하였다($p < 0.001$). Bootstrap 검정에서도 Recall은 6.8%p, F1-score는 3.4%p, Accuracy는 2.6%p 향상되어 통계적으로 유의한 개선을 보였다. 또한 Brier score는 0.017 감소하여 예측 확률의 신뢰도 측면에서도 유의한 개선이 확인되었다. 반면 Precision의 차이는 0.004로 통계적으로 유의하지 않았다. 세부 결과는 부록 5의 표 5-1에 제시하였다.

성별 및 연령별 하위그룹 분석 결과, 제안한 Hybrid Fusion 모델은 다양한 환자 군에서 비교적 안정적인 성능을 보였다. 성별 분석에서는 여성과 남성 모두 AUC가 0.82 이상으로 나타났으며, 성별에 따른 뚜렷한 성능 저하는 관찰되지 않았다. 연령별 분석에서는 65세 미만 그룹과 75세 이상 그룹의 AUC가 각각 0.834와 0.812로 큰 차이를 보이지 않았으나, 65-74세 그룹은 AUC 0.797로 상대적으로 낮게 나타났다. 다만 65-74세 그룹은 평균 표본 수가 적기 때문에 그룹에 포함된 환자들의 특성에 따라 성능 값이 더 흔들렸을 가능성이 있다. 세부 결과는 부록 5의 표 5-2에 제시하였다.

Temporal holdout 평가는 시간적으로 분리된 데이터에서 모델의 일반화 가능성을 확인하고, 기존 데이터에서 뇌졸중군과 비뇌졸중군의 수집 연도 범위가 일부 달랐던 점을 보완적으로 검토하기 위해 수행하였다. 이를 위해 두 군 모두 2015-2019년 자료로 제한한 뒤, 기록 시점을 기준으로 학습, 검증, 테스트 셋을 7:1:2의 비율로 분할하였다. 이 과정에서 전체 ECG 수는 3,132건으로 감소하였고, 전체 데이터 셋 대비 양성 비율도 35.82%로 낮아져 전체적인 성능이 저하되었다. 이러한 조건에서도 Hybrid Fusion 모델은 AUC 0.758을 기록하여 Signal-Only 모델의 AUC 0.718보다 0.040 높은 성능을 보였다. 이는 시간적으로 분리된 평가 환경에서도 ECG 신호와 피처를 함께 활용하는 방식이 ECG 신호만 사용하는 경우보다 전반적인 판별 성능을 향상시킬 수 있음을 보여준다. 세부적인 데이터 구성은 부록 5의 표 5-3에, 분류 성능 결과는 표 5-4에 제시하였다.

제6장 논의

1. 제안 모델의 성능 및 의의

일반적인 멀티모달 접근은 서로 다른 데이터 소스에서 얻어진 정보를 결합하여 각 모달리티 간의 상호보완성을 활용하는 것을 목표로 한다. 본 연구는 이와 달리, 동일한 12-lead ECG 기록에서 얻어진 정보를 ECG 신호와 ECG 피처라는 서로 다른 형태의 표현으로 분리하여 활용하였다. 연구 결과, ECG 신호와 피처를 함께 활용한 Hybrid Fusion 모델은 단일모달 접근보다 우수한 뇌졸중 분류 성능을 보였다. Signal-Only 모델이 Feature-Only 모델보다 높은 성능을 보인 것은 뇌졸중 관련 ECG 이상을 탐지하는 데 원시 신호 파형 정보가 중요한 역할을 함을 시사한다. 반면, Hybrid Fusion 모델이 Signal-Only 모델보다 더 높은 성능을 보인 점은 신호만으로는 충분히 반영되지 않는 구조화된 수치 정보가 피처에 포함되어 있음을 의미한다. 즉, ECG 신호와 피처는 동일한 ECG 기록에서 파생되었음에도 서로 다른 정보 특성을 가지며, 이를 각각에 적합한 방식으로 모델링한 뒤 융합할 때 분류 성능이 향상될 수 있음을 확인하였다. 이러한 결과는 단일 데이터 기반의 다중 표현 융합에서도 멀티모달 접근과 같은 상호보완적 효과를 얻을 수 있음을 실험적으로 검증했다는 점에서 의의가 있다.

본 연구에서 신호 기반 분류의 한계는 뇌졸중군과 비뇌졸중군 간 ECG 형태가 유사한 양상을 보일 수 있다는 점이다. 특히 본 연구의 비뇌졸중군은 정상 대조군이 아니라 병원 입원환자로 구성되어 있어, 다양한 기저질환이나 심혈관계 이상으로 인해 비정상적인 ECG 소견을 보일 수 있다. 따라서 두 군 모두에서 ECG 이상이 나타날

가능성이 있으며, 이 경우 ECG 신호의 세부적인 차이를 구별하는 데 어려움이 있을 수 있다. 또한 본 연구의 신호 기반 모델은 구간 단위로 분할되거나 별도로 전처리된 데이터가 아닌 원시 ECG 신호를 입력으로 사용하였으므로, 세부적인 파형 차이를 구분하는 데 어려움이 있었을 가능성이 있다. 실제로 Grad-CAM 분석 결과, 오분류 사례에서는 주요 ECG 파형 구간에 대한 활성화가 거의 나타나지 않아 모델이 예측에 필요한 국소적 신호 패턴을 충분히 포착하지 못했을 가능성이 확인되었다. 이는 lead 별 분석이나 구간 단위 분석 등을 통해 ECG 신호를 보다 세밀하게 활용할 경우, 두 군 간 미세한 차이를 반영하여 신호 기반 분류 성능을 개선할 수 있음을 시사한다.

한편, 피처 기반 분류에서는 모든 피처가 분류 성능에 기여한 것은 아니었다. 일부 결측은 수집 시기나 측정 장비와 밀접하게 관련되어 있었고, 다른 일부는 연령 또는 질환과 관련된 결측 패턴을 보였다. 이는 결측 발생 배경에 따른 피처 선별이 필요함을 시사한다. 또한 HRV 관련 피처의 추정 안정성의 한계가 있었고 정보가 유의미하지 않아 성능에 부정적인 영향을 미쳤다. 따라서 데이터 조건에 적합하고 신뢰성 있게 추출 가능한 피처를 사용하는 것이 중요하다. 그룹 간 피처 중복도 확인되었다. 그러나 이러한 변수를 제거하는 것이 항상 성능 향상으로 이어지지 않는다는 점도 피처 간 중복성이 모델 성능에 미치는 영향을 추가적으로 검토할 필요가 있음을 보여준다.

기본 Early Fusion 모델과 Interaction Early Fusion 모델을 단독으로 비교했을 때는 Interaction Early Fusion 모델이 모든 평가 지표에서 더 우수한 성능을 보였다. 이는 Raw Interaction Branch를 통해 ECG 신호와 피처의 초기 상호작용 정보를 추가로 반영하는 것이 두 모달리티의 결합 표현을 학습하는 데 효과적이었음을 시사한다. 그러나 Hybrid Fusion 모델의 브랜치로 적용했을 때는 Interaction Early Fusion 모델을 사용한 경우가 기본 Early Fusion을 사용한 경우보다 Recall, F1-score, AUC, Brier score는 향상되었으나 Accuracy와 Precision은 낮게 나타났다. 이는 Interaction Early Fusion 모델이 Hybrid Fusion 모델 내에서 양성을

더 적극적으로 탐지하는 방향으로 기여하여 민감도와 전반적인 판별 성능은 개선했지만, 일부 음성을 양성으로 분류하는 경우가 증가하면서 Precision과 Accuracy가 감소했음을 의미한다. 따라서 Interaction Early Fusion 모델은 Hybrid Fusion 구조에서 모든 지표를 일관되게 향상시키기보다는 뇌졸중 탐지 성능을 보완하는 역할을 한 것으로 해석된다.

2. 임상적 의의

본 모델은 응급실 초기 진료 흐름에서 고위험 환자를 조기에 식별하기 위한 보조적 선별 도구로 이용될 수 있다. 예를 들어, 응급실에 신경학적 증상이나 비특이적 어지러움, 실신, 의식 저하, 편측 약화, 언어장애 등의 증상으로 내원한 환자의 초기 활력징후 측정과 12-lead ECG 측정은 비교적 빠르게 이루어질 수 있다 [61,62]. 이때 모델이 ECG로부터 뇌졸중 위험 확률을 실시간으로 예측하면, 해당 정보는 응급실 중증도 분류 단계 또는 초진 직후의 참고 지표로 활용될 수 있다. 고위험 확률을 보이는 환자는 보다 빠른 신경과 평가, 뇌 영상검사 우선 배정, 또는 집중 모니터링 대상으로 분류될 수 있다. 따라서 본 모델은 초기 평가 단계에서 고위험 환자의 우선순위를 조정하기 위한 보조적 의사결정 도구로서의 가능성을 시사한다.

3. 연구의 한계 및 향후 연구

본 연구는 단일 기관에서 수집된 후향적 데이터에 기반하여 수행되었기 때문에, 다른 의료기관이나 장비 환경에서도 동일한 성능이 재현되는지는 아직 확인되지 않았다. 뇌졸중군과 비뇌졸중군의 데이터가 부분적으로 서로 다른 기간에 수집되었기 때문에, 수집 연도나 기기 유형의 차이가 모델 성능에 영향을 미쳤을 가능성이 있다.

따라서 temporal holdout 평가를 수행하여 시간적 일반화 가능성을 추가적으로 확인하였다. 그러나 기간 재구성 과정에서 표본 수가 감소하고 양성 클래스 비율이 낮아졌기 때문에 해당 결과를 전체 데이터 셋에 대한 일반적인 성능으로 해석할 수 없다. 또한 실제 적용 가능성을 높이기 위해 임상정보 사용을 최소화하였다는 장점이 있지만, 그만큼 중요한 임상적 맥락 정보가 충분히 반영되지 못한 한계도 있다. 향후에는 다양한 기관과 환자군을 포함한 독립적인 외부 데이터 셋을 활용하여 모델의 일반화 가능성을 추가적으로 평가할 필요가 있으며, 이때 수집 시점에 따른 시간적 편향이 최소화된 데이터 구성이 요구된다. 또한 실제 진료 흐름에서 모델이 고위험 환자 선별에 효과적으로 활용될 수 있는지 확인하기 위한 전향적 평가가 요구된다. 나아가 환자의 병력, 임상검사 결과, 영상 정보 등 추가 임상정보를 통합한 확장 연구를 수행함으로써, ECG 기반 뇌졸중 분류 모델의 예측 신뢰도와 임상적 적용 가능성을 더욱 강화할 수 있을 것이다.

제7장 결론

본 연구에서는 12-lead ECG 신호와 ECG 피처를 활용하는 ECG 중심의 하이브리드 멀티모달 프레임워크를 제안하고, 실제 임상 코호트에서 그 유효성을 검증하였다. 제안한 프레임워크는 Interaction Early Fusion 구조를 통해 두 모달리티 간 상호작용을 학습하고, 이후 late fusion을 통해 각 브랜치의 예측을 통합함으로써 표현 수준 융합과 예측 수준 융합의 장점을 함께 반영하도록 설계되었다. 실험 결과, 제안한 Hybrid Fusion 모델은 단일모달 Signal-Only 모델 및 기존 baseline 멀티모달 모델보다 우수한 분류 성능과 확률 예측 안정성을 보였다. 이러한 결과는 하나의 ECG 데이터로부터 파생된 서로 다른 두 형태의 정보를 통합하는 전략이 뇌졸중 분류 성능 향상에 실질적으로 기여할 수 있음을 보여준다. 또한 본 연구는 임상정보에 대한 의존성을 최소화하면서도 실제 병원에서 수집된 표준 10초 12-lead ECG만으로 유의미한 성능 향상을 확인하였다는 점에서, 제안한 프레임워크가 실제 임상 환경에서 조기 위험 선별을 지원하는 비침습적 의사결정 보조 도구로 활용될 가능성을 제시한다. 향후에는 다기관 외부 검증과 전향적 평가를 통해 모델의 일반화 가능성과 임상적 유효성을 보다 엄밀히 확인하고, 뇌졸중 세부 유형 분류, 예후 예측과 같은 보다 확장된 임상 과제로 발전시킬 필요가 있다.

참 고 문 헌

- [1] D. Kuriakose and Z. Xiao, "Pathophysiology and treatment of stroke: Present status and future perspectives," *International Journal of Molecular Sciences*, vol. 21, no. 20, Art. no. 7609, 2020.
- [2] V. L. Feigin, M. Brainin, B. Norrving, S. O. Martins, J. Pandian, P. Lindsay, M. F. Grupper, and I. Rautalin, "World Stroke Organization: Global stroke fact sheet 2025," *International Journal of Stroke*, vol. 20, no. 2, pp. 132-144, 2025.
- [3] K. Rathakrishnan, S.-N. Min, and S. J. Park, "Evaluation of ECG features for the classification of post-stroke survivors with a diagnostic approach," *Applied Sciences*, vol. 11, no. 1, Art. no. 192, 2021.
- [4] R. E. Latchaw, M. J. Alberts, M. H. Lev, J. J. Connors, R. E. Harbaugh, R. T. Higashida, R. Hobson, C. S. Kidwell, W. J. Koroshetz, V. Mathews, P. Villablanca, S. Warach, and B. Walters, "Recommendations for imaging of acute ischemic stroke: A scientific statement from the American Heart Association," *Stroke*, vol. 40, no. 11, pp. 3646-3678, Nov. 2009.
- [5] J. A. Chalela, C. S. Kidwell, L. M. Nentwich, M. Luby, J. A. Butman, A. M. Demchuk, M. D. Hill, N. Patronas, L. Latour, and S. Warach, "Magnetic resonance imaging and computed tomography in emergency assessment of patients with suspected acute stroke: A prospective comparison," *The Lancet*, vol. 369, no. 9558, pp. 293-298, Jan. 2007.
- [6] N. Rafie, A. H. Kashou, and P. A. Noseworthy, "ECG interpretation: Clinical relevance, challenges, and advances," *Hearts*, vol. 2, no. 4, pp. 505

-513, 2021.

[7] J. L. Saver, "Time is brain—quantified," *Stroke*, vol. 37, no. 1, pp. 263–266, 2006.

[8] M. Togha, A. Sharifpour, H. Ashraf, M. Moghadam, and M. A. Sahraian, "Electrocardiographic abnormalities in acute cerebrovascular events in patients with/without cardiovascular disease," *Annals of Indian Academy of Neurology*, vol. 16, no. 1, pp. 66–71, 2013.

[9] P. Asadi, S. M. Zia Ziabari, D. Naghshe Jahan, and A. Jafarian Yazdi, "Electrocardiogram changes as an independent predictive factor of mortality in patients with acute ischemic stroke: A cohort study," *Archives of Academic Emergency Medicine*, vol. 7, no. 1, p. e27, 2019.

[10] D. Ruthirago, P. Julayanont, P. Tantrachoti, J. Kim, and K. Nugent, "Cardiac arrhythmias and abnormal electrocardiograms after acute stroke," *The American Journal of the Medical Sciences*, vol. 351, no. 1, pp. 112–118, 2016.

[11] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.

[12] C.-H. Lin, Z.-Y. Liu, P.-H. Chu, J.-S. Chen, H.-H. Wu, M.-S. Wen, C.-F. Kuo, and T.-Y. Chang, "A multitask deep learning model utilizing electrocardiograms for major cardiovascular adverse events prediction," *npj Digital Medicine*, vol. 8, no. 1, p. 1, 2025.

[13] Y. Qiu, H. Guo, S. Wang, S. Yang, X. Peng, D. Xiayao, R. Chen, J. Yang, J. Liu, M. Li, Z. Li, H. Chen, and M. Chen, "Deep learning-based multimodal fusion of the surface ECG and clinical features in prediction of atrial fibrillation recurrence following catheter ablation," *BMC Medical*

Informatics and Decision Making, vol. 24, no. 1, p. 225, 2024.

[14] A. Rawshani, A. Rawshani, G. Smith, J. Boren, D. L. Bhatt, M. Börjesson, J. Engdahl, P. Kelly, A. Louca, T. Ramunddal, E. Andersson, E. Omerovic, Z. Mandalenakis, and V. Gupta, “Integrating deep learning with ECG, heart rate variability and demographic data for improved detection of atrial fibrillation,” *Open Heart*, vol. 12, no. 1, p. e003185, 2025.

[15] A. S. Tseng, M. Shelly-Cohen, I. Z. Attia, P. A. Noseworthy, P. A. Friedman, J. K. Oh, and F. Lopez-Jimenez, “Spectrum bias in algorithms derived by artificial intelligence: A case study in detecting aortic stenosis using electrocardiograms,” *European Heart Journal - Digital Health*, vol. 2, no. 4, pp. 561–567, Dec. 2021.

[16] A. Jaya Prakash, A. Nasreddine Belkacem, I. M. Elfadel, H. F. Jelinek, and M. Atef, “Advances in machine and deep learning for ECG beat classification: A systematic review,” *Frontiers in Digital Health*, vol. 7, 2025.

[17] D. Zhang, X. Lan, S. Geng, Q. Zhao, S. Fan, M. Feng, and S. Hong, “MEETI: A multimodal ECG dataset from MIMIC-IV-ECG with signals, images, features and interpretations,” *Scientific Data*, vol. 13, no. 1, p. 527, 2026.

[18] A. Vafaei Sadr, M. Mareboina, D. Orabueze, N. Sarkar, S. S. Hejajian, A. Vemuri, R. Shah, A. Maheshwari, R. Zand, and V. Abedi, “Integration of EHR and ECG data for predicting paroxysmal atrial fibrillation in stroke patients,” *Bioengineering*, vol. 12, no. 9, p. 961, 2025.

[19] R. K. Akyea, G. Ntaios, E. Kontopantelis, G. Georgiopoulos, D. Soria, F. W. Asselbergs, J. Kai, S. F. Weng, and N. Qureshi, “A population-based study exploring phenotypic clusters and clinical outcomes in stroke using

unsupervised machine learning approach,” PLOS Digital Health, vol. 2, no. 9, p. e0000334, 2023.

[20] Z. Yang, X. Wang, J. Wang, Q. Guang, X. Ding, H. Liu, Y. Xu, J. Zhao, and M. Bai, “Multimodal transformer-based electrocardiogram analysis for cardiovascular comorbidity detection: Model development and validation study,” JMIR Formative Research, vol. 10, p. e80815, 2026.

[21] P. Kligfield, L. S. Gettes, J. J. Bailey, R. Childers, B. J. Deal, E. W. Hancock, G. van Herpen, J. A. Kors, P. Macfarlane, D. M. Mirvis, O. Pahlm, P. Rautaharju, and G. S. Wagner, “Recommendations for the standardization and interpretation of the electrocardiogram: Part I: The electrocardiogram and its technology,” Journal of the American College of Cardiology, vol. 49, no. 10, pp. 1109–1127, 2007.

[22] E. A. Ashley and J. Niebauer, “Conquering the ECG,” in Cardiology Explained. London, U.K.: Remedica, 2004, ch. 3.

[23] J. Pan and W. J. Tompkins, “A real-time QRS detection algorithm,” IEEE Transactions on Biomedical Engineering, vol. BME-32, no. 3, pp. 230–236, 1985.

[24] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, “Heart rate variability: Standards of measurement, physiological interpretation and clinical use,” Circulation, vol. 93, no. 5, pp. 1043–1065, 1996.

[25] R. L. Burr and M. J. Cowan, “Autoregressive spectral models of heart rate variability: Practical issues,” Journal of Electrocardiology, vol. 25, pp. 224–233, 1992.

[26] R. H. H. Groenwold, “Informative missingness in electronic health

record systems: The curse of knowing,” *Diagnostic and Prognostic Research*, vol. 4, p. 8, 2020.

[27] T. Sedlak, C. Shufelt, C. Iribarren, and C. N. B. Merz, “Sex hormones and the QT interval: A review,” *Journal of Women’s Health*, vol. 21, no. 9, pp. 933–941, 2012.

[28] Student, “The probable error of a mean,” *Biometrika*, vol. 6, no. 1, pp. 1–25, 1908.

[29] K. Pearson, “X. On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling,” *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, vol. 50, no. 302, pp. 157–175, 1900.

[30] N. Strodthoff, P. Wagner, T. Schaeffter, and W. Samek, “Deep learning for ECG analysis: Benchmarks and insights from PTB-XL,” *IEEE Journal of Biomedical and Health Informatics*, vol. 25, no. 5, pp. 1519–1528, 2021.

[31] A. H. Ribeiro, M. H. Ribeiro, G. M. M. Paixão, D. M. Oliveira, P. R. Gomes, J. A. Canazart, M. P. S. Ferreira, C. R. Andersson, P. W. Macfarlane, W. Meira Jr., T. B. Schön, and A. L. P. Ribeiro, “Automatic diagnosis of the 12-lead ECG using a deep neural network,” *Nature Communications*, vol. 11, Art. no. 1760, 2020.

[32] J. Li, S.-P. Pang, F. Xu, P. Ji, S. Zhou, and M. Shu, “Two-dimensional ECG-based cardiac arrhythmia classification using DSE-ResNet,” *Scientific Reports*, vol. 12, Art. no. 14485, 2022.

[33] L. Qin, Y. Xie, X. Liu, X. Yuan, and H. Wang, “An end-to-end 12-leading electrocardiogram diagnosis system based on deformable

convolutional neural network with good antinoise ability,” IEEE Transactions on Instrumentation and Measurement, vol. 70, Art. no. 2508313, pp. 1–13, 2021.

[34] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A large-scale hierarchical image database,” in 2009 IEEE Conference on Computer Vision and Pattern Recognition, 2009, pp. 248–255.

[35] Y. Wu, F. Yang, Y. Liu, X. Zha, and S. Yuan, “A comparison of 1-D and 2-D deep convolutional neural networks in ECG classification,” arXiv preprint arXiv:1810.07088, 2018.

[36] Z. Zhao, C. Shen, H. Tong, D. Song, Z. Deng, Q. Wen, and J. Ni, “From Images to Signals: Are Large Vision Models Useful for Time Series Analysis?” arXiv preprint arXiv:2505.24030, 2025.

[37] H. Ismail Fawaz, B. Lucas, G. Forestier, C. Pelletier, D. F. Schmidt, J. Weber, G. I. Webb, L. Idoumghar, P.-A. Muller, and F. Petitjean, “InceptionTime: Finding AlexNet for time series classification,” Data Mining and Knowledge Discovery, vol. 34, no. 6, pp. 1936–1962, 2020.

[38] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.

[39] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in Proceedings of the 36th International Conference on Machine Learning (ICML), 2019, pp. 6105–6114.

[40] Y. Gong, Y.-A. Chung, and J. Glass, “AST: Audio Spectrogram Transformer,” in Proceedings of Interspeech, 2021, pp. 571–575.

[41] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen,

“MobileNetV2: Inverted residuals and linear bottlenecks,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 4510–4520.

[42] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.

[43] A. Kadra, M. Lindauer, F. Hutter, and J. Grabocka, “Well-tuned simple nets excel on tabular datasets,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021.

[44] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.

[45] J. Ngiam, A. Khosla, M. Kim, J. Nam, H. Lee, and A. Y. Ng, “Multimodal deep learning,” in *Proceedings of the 28th International Conference on Machine Learning*, 2011, pp. 689–696.

[46] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, “Multimodal machine learning: A survey and taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019.

[47] S. R. Stahlschmidt, B. Ulfenborg, and J. Synnergren, “Multimodal deep learning for biomedical data fusion: A review,” *Briefings in Bioinformatics*, vol. 23, no. 2, Art. no. bbab569, 2022.

[48] R. Ramachandram and G. W. Taylor, “Deep multimodal learning: A survey on recent advances and trends,” *IEEE Signal Processing Magazine*, vol. 34, no. 6, pp. 96–108, 2017.

[49] C. Cui, H. Yang, Y. Wang, S. Zhao, Z. Asad, L. A. Coburn, K. T.

- Wilson, B. A. Landman, and Y. Huo, “Deep multimodal fusion of image and non-image data in disease diagnosis and prognosis: A review,” *Progress in Biomedical Engineering*, vol. 5, no. 2, Art. no. 022001, 2023.
- [50] D. Lahat, T. Adali, and C. Jutten, “Multimodal data fusion: An overview of methods, challenges, and prospects,” *Proceedings of the IEEE*, vol. 103, no. 9, pp. 1449–1477, 2015.
- [51] H. Abuhamad, S. Zainudin, and A. Abu Bakar, “Integrative multimodal hybrid data fusion for mortality prediction,” *Scientific Reports*, vol. 16, Art. no. 5803, 2026.
- [52] Y. Li et al., “A review of deep learning-based information fusion techniques for multimodal medical image classification,” *Computers in Biology and Medicine*, vol. 177, Art. no. 108635, 2024.
- [53] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [54] K. McKeen, S. Masood, A. Toma, B. Rubin, and B. Wang, “ECG-FM: An open electrocardiogram foundation model,” *JAMIA Open*, vol. 8, no. 5, Art. no. ooaf122, 2025.
- [55] E. Coppola, M. Savardi, M. Massussi, M. Adamo, M. Metra, and A. Signoroni, “HuBERT-ECG as a self-supervised foundation model for broad and scalable cardiac applications,” *medRxiv*, 2024.
- [56] W. J. Youden, “Index for rating diagnostic tests,” *Cancer*, vol. 3, no. 1, pp. 32–35, 1950.
- [57] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via

- gradient-based localization,” in Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 618-626.
- [58] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in Advances in Neural Information Processing Systems, 2017.
- [59] E. R. DeLong, D. M. DeLong, and D. L. Clarke-Pearson, “Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach,” *Biometrics*, vol. 44, no. 3, pp. 837-845, 1988.
- [60] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1993.
- [61] College of Emergency Nursing Australasia and Australasian College for Emergency Medicine, “Joint position statement on vital signs monitoring in emergency departments,” 2023.
- [62] W. K. Shen, R. S. Sheldon, D. G. Benditt, M. I. Cohen, D. E. Forman, Z. D. Goldberger, et al., “2017 ACC/AHA/HRS guideline for the evaluation and management of patients with syncope: A report of the American College of Cardiology/American Heart Association Task Force on Clinical Practice Guidelines and the Heart Rhythm Society,” *Journal of the American College of Cardiology*, vol. 70, no. 5, pp. e39-e110, 2017.

A Hybrid Fusion Multimodal Framework for Stroke Classification Using ECG Signals and Measurements

2026.

Master's Degree

Im, So Yun

Department of Computer Engineering

Advisor Prof. Kim, Yu Seop

Stroke is one of the leading causes of death and long-term disability worldwide, and early identification is crucial. Electrocardiography (ECG) has received attention as a non-invasive tool for detecting stroke-related abnormalities; however, unimodal approaches that rely only on ECG signals have limitations in fully capturing stroke-related ECG characteristics. In this study, we propose a hybrid fusion-based multimodal framework for stroke classification that jointly utilizes two types of information derived from ECG: raw 12-lead ECG signals and quantitative ECG-derived features. The proposed framework consists of two stages. First, an Interaction Early Fusion model, composed of a signal encoder, a feature encoder, and a Raw Interaction Branch, is used to learn inter-modal interactions at both the raw data level and the representation level. Second, Hybrid Fusion is applied by averaging the logits from the Signal-Only model, Feature-Only model, and Interaction Early Fusion model. The proposed model achieved

an AUC of 0.832 and a Recall of 82.7%, improving AUC by 0.034 and Recall by 6.7 percentage points compared with the Signal-Only model.

Keywords: Stroke classification, Electrocardiography, ECG measurements, Multimodal learning, Hybrid fusion

부 록

<부록 1> ECG 피치의 통계 분석 결과

표 1-1은 MUSE 변수에 대해 뇌졸중군과 비뇌졸중군 간의 평균, 표준편차 및 p-value를 제시한다.

표 1-1. MUSE 변수의 통계 분석 결과

MUSE Variables (n = 25)			
Variable	Stroke	Non-Stroke	p-value
VentricularRate	75.80±17.84	76.56±18.94	0.186
AtrialRate	86.08±52.73	84.27±46.22	0.24
GlobalRR	831.45±181.80	824.44±177.58	0.21
QRSCount	12.45±2.98	12.58±3.14	0.159
PRInterval	166.46±25.60	162.24±26.05	<0.001
QRSDuration	92.26±15.82	93.54±18.13	0.016
QTInterval	404.95±44.21	396.39±45.90	<0.001
QTCorrected	446.90±30.82	439.57±39.10	<0.001
QTcFrederica	431.84±28.22	424.29±35.57	<0.001
PharmaRRinterval	832.09±165.94	829.12±172.38	0.573
PharmaPPinterval	812.26±215.77	813.12±208.64	0.897
QOnset	219.21±6.55	218.60±6.84	0.004
QOffset	265.34±8.68	265.37±8.75	0.896
POnset	135.91±14.52	137.94±14.38	<0.001
POffset	186.12±14.88	188.91±13.89	<0.001
TOffset	421.68±22.80	416.80±23.27	<0.001
PAxis	46.19±23.78	49.47±22.99	<0.001
RAxis	27.38±37.69	37.24±42.51	<0.001
TAxis	46.44±46.15	48.67±47.99	0.128
PRInterval_missing	0.15±0.36	0.12±0.32	0.001
QTcFrederica_missing	0.04±0.21	0.00±0.00	<0.001
POnset_missing	0.15±0.35	0.11±0.31	<0.001
POffset_missing	0.15±0.35	0.11±0.31	<0.001
PAxis_missing	0.12±0.33	0.12±0.32	0.778
Gender	0.58±0.49	0.55±0.50	0.02

표 1-2는 Extracted 변수에 대해 뇌졸중군과 비뇌졸중군 간의 평균, 표준편차 및 p-value를 제시한다.

표 1-2. Extracted 변수의 통계 분석 결과

Extracted Variables (n = 25)			
Variable	Stroke	Non-Stroke	p-value
HR	76.89±17.56	77.54±18.64	0.252
RR-I	817.59±172.27	813.03±172.05	0.395
PRQ	238.57±36.94	232.88±36.15	<0.001
QRS	93.80±19.58	90.15±19.20	<0.001
QT	360.78±58.34	348.50±61.08	<0.001
QTc	401.41±51.97	389.18±58.16	<0.001
ST	121.67±43.74	113.88±45.54	<0.001
P-H	58.59±64.02	52.78±68.27	0.005
R-H	56.70±157.74	34.02±174.78	<0.001
RMSSD	139.73±109.23	130.34±113.79	0.007
SDSD	144.39±114.14	134.56±119.68	0.007
pNN50	49.66±24.94	46.94±24.34	<0.001
LF	0.00±0.02	0.00±0.10	0.572
HF	0.01±0.05	0.01±0.14	0.79
VLF	0.00±0.00	0.00±0.02	0.691
LF/HF	0.31±0.20	0.32±0.22	0.388
Kurtosis	11.04±7.37	12.45±11.40	<0.001
Skewness	1.72±1.56	1.85±1.71	0.01
Peak value	800.01±375.56	816.72±487.58	0.218
Impulse factor	8.42±3.10	8.96±3.55	<0.001
Crest factor	5.43±1.34	5.62±1.43	<0.001
LF_missing	0.16±0.36	0.15±0.36	0.588
HF_missing	0.16±0.36	0.15±0.36	0.588
VLF_missing	0.16±0.36	0.15±0.36	0.588
LF/HF_missing	0.16±0.36	0.15±0.36	0.588

<부록 2> ECG 피쳐 기반 단일모달 분류 성능 비교

표 2-1은 그룹별 유의성 순위에 따라 구성한 피쳐 셋의 성능 변화를 KNN 모델로 평가한 결과이다. 추가적으로, Extracted 그룹에서는 선행연구 [3]에서 우수한 성능을 보인 LF/HF, ST, QT 조합을 함께 비교하였다.

표 2-1. 그룹별 유의성 순위 기반 피쳐 셋에 따른 KNN 성능 비교

Group	Feature set	Top-N	KNN 5-fold CV mean (95% CI)					
			Accuracy	Precision	Recall	F1-score	AUC	Brier
Extracted	LF/HF, ST, QT [3]	3	51.2 (47.7-54.7)	52.1 (49.8-54.4)	51.3 (23.4-79.3)	50.1 (35.2-65.0)	0.509 (0.488-0.529)	0.269 (0.264-0.273)
	Significant Features (p<0.05)	3	52.2 (50.7-53.6)	53.8 (52.1-55.4)	53.0 (34.1-72.0)	52.4 (42.3-62.4)	0.537 (0.508-0.566)	0.265 (0.254-0.276)
		5	54.3 (52.5-56.1)	57.7 (54.1-61.3)	43.9 (34.8-53.0)	49.5 (44.6-54.3)	0.579 (0.549-0.610)	0.248 (0.242-0.255)
		7	56.0 (54.0-58.0)	56.5 (55.7-57.3)	63.0 (50.7-75.3)	59.3 (53.1-65.4)	0.595 (0.570-0.621)	0.245 (0.239-0.251)
		10	55.9 (52.2-59.6)	58.5 (55.1-61.9)	49.4 (33.5-65.4)	52.9 (43.4-62.3)	0.584 (0.553-0.616)	0.249 (0.242-0.255)
		14	55.1 (52.4-57.8)	57.7 (55.8-59.6)	47.5 (33.6-61.5)	51.6 (43.2-60.0)	0.583 (0.559-0.607)	0.246 (0.240-0.251)
	All Features	25	55.6 (53.2-58.0)	56.6 (54.5-58.7)	59.1 (44.9-73.3)	57.4 (50.4-64.3)	0.570 (0.550-0.591)	0.250 (0.244-0.257)
MUSE	Significant Features (p<0.05)	3	57.4 (53.2-61.6)	58.8 (53.6-64.0)	61.7 (49.5-73.9)	59.6 (54.9-64.3)	0.586 (0.537-0.635)	0.284 (0.261-0.307)
		5	59.4 (57.2-61.7)	59.0 (55.4-62.6)	71.8 (60.9-82.7)	64.4 (61.1-67.7)	0.635 (0.595-0.675)	0.236 (0.223-0.248)
		7	61.1 (57.0-65.2)	61.3 (58.4-64.1)	66.4 (51.1-81.8)	63.3 (55.3-71.2)	0.649 (0.607-0.691)	0.233 (0.221-0.244)
		10	60.0 (57.8-62.2)	60.6 (59.9-61.4)	63.5 (50.5-76.6)	61.7 (55.3-68.1)	0.652 (0.620-0.684)	0.230 (0.221-0.240)
		16	58.8 (55.9-61.7)	60.6 (56.5-64.7)	58.2 (41.4-75.1)	58.6 (49.8-67.4)	0.646 (0.616-0.675)	0.233 (0.220-0.245)
	All Features	25	60.3 (58.5-62.2)	63.0 (59.6-66.4)	56.8 (46.4-67.2)	59.4 (55.1-63.6)	0.665 (0.642-0.688)	0.229 (0.218-0.239)

표 2-2는 그룹별 유의성 순위에 따라 구성된 피쳐 셋의 성능 변화를 MLP 모델로 평가한 결과이다. 추가적으로, Extracted 그룹에서는 선행연구 [3]에서 우수한 성능을 보인 LF/HF, ST, QT 조합을 함께 비교하였다.

표 2-2. 그룹별 유의성 순위 기반 피쳐 셋에 따른 MLP 성능 비교

Group	Feature set	Top-N	MLP 5-fold CV mean (95% CI)					
			Accuracy	Precision	Recall	F1-score	AUC	Brier
Extracted	LF/HF, ST, QT [3]	3	53.1 (51.1-55.1)	56.1 (51.6-60.6)	45.2 (27.9-62.4)	48.9 (40.3-57.5)	0.551 (0.530-0.572)	0.249 (0.246-0.251)
	Significant Features (p<0.05)	3	54.7 (52.3-57.1)	57.1 (54.2-60.0)	47.8 (38.7-56.9)	51.8 (45.9-57.7)	0.563 (0.543-0.583)	0.247 (0.245-0.250)
		5	56.6 (55.8-57.5)	57.4 (56.4-58.4)	60.9 (55.2-66.6)	59.1 (56.4-61.7)	0.578 (0.560-0.596)	0.246 (0.244-0.248)
		7	57.3 (54.5-60.2)	58.3 (53.1-63.4)	65.4 (52.0-78.7)	60.9 (57.6-64.2)	0.601 (0.575-0.628)	0.242 (0.238-0.246)
		10	56.5 (52.9-60.1)	57.6 (53.3-61.8)	59.9 (48.5-71.3)	58.4 (52.5-64.2)	0.598 (0.572-0.624)	0.243 (0.238-0.248)
		14	59.8 (58.4-61.2)	60.1 (57.7-62.4)	66.0 (55.9-76.1)	62.6 (58.6-66.6)	0.612 (0.598-0.625)	0.241 (0.238-0.244)
	All Features	25	57.5 (54.6-60.4)	58.2 (54.7-61.7)	65.0 (44.9-85.1)	60.4 (52.1-68.7)	0.611 (0.581-0.641)	0.241 (0.235-0.246)
MUSE	Significant Features (p<0.05)	3	58.7 (56.1-61.3)	59.0 (55.6-62.4)	66.1 (60.1-72.2)	62.2 (60.5-63.9)	0.629 (0.599-0.658)	0.235 (0.228-0.242)
		5	60.5 (57.2-63.8)	60.0 (55.3-64.8)	71.9 (63.5-80.3)	65.1 (62.7-67.5)	0.645 (0.610-0.679)	0.232 (0.224-0.240)
		7	61.0 (58.2-63.9)	62.7 (59.7-65.7)	60.0 (52.3-67.6)	61.2 (56.6-65.7)	0.648 (0.617-0.680)	0.231 (0.223-0.239)
		10	61.6 (59.8-63.4)	61.0 (58.7-63.3)	70.7 (66.3-75.1)	65.4 (63.7-67.2)	0.657 (0.625-0.690)	0.229 (0.220-0.238)
		16	65.2 (63.1-67.3)	66.3 (63.6-69.1)	66.1 (57.6-74.6)	66.0 (62.2-69.8)	0.699 (0.673-0.726)	0.219 (0.211-0.228)
	All Features	25	65.3 (63.6-67.1)	66.7 (65.5-68.0)	65.3 (56.1-74.6)	65.8 (61.5-70.2)	0.702 (0.668-0.737)	0.218 (0.208-0.229)

<부록 3> ECG 피쳐 분석 및 피쳐 셋 구성 실험

표 3-1은 뇌졸중군과 비뇌졸중군 간의 피쳐 결측률 차이를 비교한 결과를 제시한다. 여기서 Missing rate는 전체 샘플에서 해당 피쳐가 결측된 비율을 의미하며, Stroke와 Non-Stroke는 각 군에서 해당 피쳐가 결측된 비율을 나타낸다.

표 3-1. 뇌졸중군과 비뇌졸중군의 피쳐 결측률 비교

Group	Missing Feature	Missing rate	Stroke	Non-Stroke	Diff	P-value
MUSE	QTcFrederica	0.023	0.045	0	0.045	<0.001
	POnset	0.127	0.146	0.108	0.038	<0.001
	POffset	0.127	0.146	0.108	0.038	<0.001
	PRInterval	0.137	0.153	0.119	0.035	0.001
	PAxis	0.119	0.121	0.117	0.003	0.742
Extracted	LF	0.153	0.156	0.150	0.006	0.559
	HF	0.153	0.156	0.150	0.006	0.559
	VLF	0.153	0.156	0.150	0.006	0.559
	LF/HF	0.153	0.156	0.150	0.006	0.559

표 3-2는 결측 발생과 수집 조건 간의 연관성을 분석한 결과를 제시한다. 이때 결측 여부 예측 AUC가 0.60 이상인 항목만 표에 포함하였다. 각 항목에는 관련 변수, 해당 값 또는 범주, 오즈비(Odds Ratio, OR)⁷⁾, p-value, AUC를 함께 제시하였다. OR은 1보다 큰 경우 결측 발생 가능성의 증가를, 1보다 작은 경우 감소를 의미한다.

표 3-2. 데이터 조건에 따른 피쳐 결측 양상

Group	Missing Feature	Predictor	Value/Category	OR	p-value	AUC
MUSE	QTcFrederica	Year	Continuous	0.182	<0.001	0.976
	QTcFrederica	Device	MAC5K	6.965	<0.001	0.883
	QTcFrederica	Device	MAC55	0.133	<0.001	0.883
	POnset	Age	Continuous	1.059	<0.001	0.715
	POffset	Age	Continuous	1.059	<0.001	0.715
	PRInterval	Age	Continuous	1.058	<0.001	0.712
	PAxis	Age	Continuous	1.057	<0.001	0.712

7) 오즈(odds)는 사건이 발생할 확률과 발생하지 않을 확률의 비로, 결측 발생 확률이 p일 때 $p/(1-p)$ 로 정의된다.

표 3-3은 절대 상관계수($|r|$)가 0.80 이상으로 나타난 MUSE 피처와 Extracted 피처 간의 상관관계 및 이에 대한 해석을 요약하여 제시한다.

표 3-3. MUSE 피처와 Extracted 피처 간 상관관계 및 해석

Extracted	MUSE	r	Interpretation
HR (bpm)	VentricularRate	0.959	동일한 심박수 개념
	QRSCount	0.944	심박수 관련 중복
	GlobalRR	-0.906	심박수와 RR 간격 간 역상관 관계
	PharmaRRinterval	-0.859	심박수와 RR 간격 간 역상관 관계
RR-I (ms)	GlobalRR	0.959	동일한 RR 간격 개념
	VentricularRate	-0.912	심박수와 RR 간격 간 역상관 관계
	PharmaRRinterval	0.907	RR 간격 관련 중복
	QRSCount	-0.896	심박수와 RR 간격 간 역상관 관계

<부록 4> 절제 실험

1) 임베딩 크기 구성의 영향

표 4-1은 임베딩 크기 구성에 따른 Interaction Early Fusion 모델과 Hybrid Fusion 모델의 성능 변화를 비교한 결과이다. 본 연구에서는 Signal Encoder, Feature Encoder, Raw Interaction Branch에 각각 512, 128, 128 차원의 임베딩을 할당한 설정을 사용하였으며, 이와 비교하기 위해 세 브랜치의 임베딩 크기를 모두 256으로 동일하게 설정한 경우를 함께 평가하였다.

표 4-1. 임베딩 크기 구성에 따른 성능 비교

Model	Embedding Size	Accuracy	Precision	Recall	F1-score	AUC	Brier
Interaction Early Fusion	(512, 128, 128)	73.7 (71.7-75.7)	72.1 (68.8-75.4)	80.2 (74.7-85.8)	75.8 (74.3-77.4)	0.815 (0.789-0.841)	0.179 (0.168-0.189)
	(256, 256, 256)	73.6 (70.4-76.9)	73.3 (69.8-76.7)	77.2 (71.1-83.2)	75.1 (72.1-78.1)	0.815 (0.782-0.847)	0.178 (0.165-0.191)
Hybrid Fusion	(512, 128, 128)	75.5 (73.3-77.7)	73.5 (69.3-77.7)	82.7 (74.3-91.1)	77.6 (75.1-80.1)	0.832 (0.809-0.856)	0.169 (0.157-0.181)
	(256, 256, 256)	72.6 (70.8-74.4)	71.0 (68.3-73.6)	79.4 (76.1-82.7)	74.9 (73.7-76.1)	0.802 (0.775-0.828)	0.199 (0.182-0.217)

2) Raw Interaction Branch의 영향

표 4-2는 기본 Early Fusion 모델을 적용한 Hybrid Fusion 모델과 Interaction Early Fusion 모델을 적용한 Hybrid Fusion 모델의 성능을 비교한 결과이다. 이를 통해 Raw Interaction Branch가 Hybrid Fusion 모델 성능에 미치는 영향을 평가하였다.

표 4-2. Early Fusion 전략별 Hybrid Fusion 모델 성능 비교

Early Fusion Strategy	Accuracy	Precision	Recall	F1-score	AUC	Brier
Baseline Early Fusion	75.8	74.8	80.2	77.3	0.831	0.170
	(73.7-77.8)	(70.8-78.9)	(74.7-85.7)	(75.7-78.9)	(0.804-0.858)	(0.155-0.184)
Interaction Early Fusion	75.5	73.5	82.7	77.6	0.832	0.169
	(73.3-77.7)	(69.3-77.7)	(74.3-91.1)	(75.1-80.1)	(0.809-0.856)	(0.157-0.181)

3) 임계값 선택에 따른 임상적 적용 가능성

표 4-3은 최종 Hybrid Fusion 모델에서 임계값 설정 방식에 따라 성능 지표가 어떻게 달라지는지 비교한 결과이다. 비교한 임계값은 기본 임계값 0.5, Youden index 기반 임계값, F1-score가 최대가 되는 임계값, 그리고 Sensitivity 90%를 만족하는 임계값이다. AUC와 Brier score는 임계값에 의존하지 않는 지표이므로 모든 설정에서 동일하게 유지되며, Accuracy, Precision, Recall, F1-score, FPR은 임계값 변화에 따라 달라진다.

표 4-3. 임계값 설정에 따른 Hybrid Fusion 모델 성능 비교

Type	Threshold	Accuracy	Precision	Recall	F1-score	AUC	Brier	FPR
Thr=0.5	0.500	75.5	74.4	80.2	77.0	0.832	0.169	29.5
	(0.500-0.500)	(74.4-76.6)	(71.7-77.1)	(72.2-88.1)	(74.6-79.4)	(0.809-0.856)	(0.157-0.181)	(22.6-36.3)
Youden	0.483	75.5	73.5	82.7	77.6	0.832	0.169	32.2
	(0.383-0.583)	(73.3-77.7)	(69.3-77.7)	(74.3-91.1)	(75.1-80.1)	(0.809-0.856)	(0.157-0.181)	(22.2-42.2)
F1-best	0.436	75.1	71.1	87.8	78.5	0.832	0.169	38.3
	(0.338-0.534)	(72.1-78.2)	(66.8-75.3)	(84.3-91.2)	(77.0-79.9)	(0.809-0.856)	(0.157-0.181)	(28.5-48.1)
Sens=90	0.391	73.2	68.1	90.5	77.6	0.832	0.169	45.2
	(0.335-0.447)	(70.6-75.7)	(65.4-70.8)	(86.7-94.2)	(76.2-79.1)	(0.809-0.856)	(0.157-0.181)	(37.4-53.1)

<부록 5> 일반화 및 통계 분석

1) Signal-Only 모델과 Hybrid Fusion 모델의 통계적 비교

표 5-1은 Signal-Only 모델과 Hybrid Fusion 모델의 Accuracy, Precision, Recall, F1-score, Brier score 차이를 bootstrap 검정으로 비교한 결과이다. 5000 회 반복 표본추출을 통해 두 모델 간 성능 차이의 평균, 95% 신뢰구간, p-value를 산출하였다.

표 5-1. Signal-Only 모델과 Hybrid Fusion 모델 간 통계적 비교

Metric	Mean difference (95% CI)	Bootstrap p-value
Accuracy	0.026 (0.011-0.041)	0.002
Precision	0.004 (-0.011-0.020)	0.572
Recall	0.068 (0.047-0.089)	<0.001
F1-score	0.034 (0.019-0.049)	<0.001
Brier	-0.017 (-0.022~-0.013)	<0.001

2) 성별 및 연령별 하위그룹 분석

표 5-2는 최종 Hybrid Fusion 모델의 각 fold의 테스트 셋에서 성별 및 연령 하위그룹별 성능을 계산한 뒤, 5개 fold의 평균과 95% 신뢰구간으로 요약한 결과이다. Mean total N과 Mean stroke N은 각 fold의 테스트 셋에서 해당 하위그룹에 포함된 전체 샘플 수와 뇌졸중 샘플 수의 평균을 의미한다.

표 5-2. 성별 및 연령에 따른 하위그룹 성능

Group	Subgroup	Mean total N	Mean stroke N	Accuracy	Precision	Recall	F1-score	AUC	Brier
Gender	Female	183.4	87.2	74.5 (71.5-77.5)	70.6 (62.5-78.8)	81.4 (72.3-90.5)	75.1 (72.8-77.5)	0.826 (0.794-0.859)	0.172 (0.156-0.188)
	Male	233.2	127.2	76.3 (74.5-78.2)	75.6 (73.5-77.7)	83.7 (74.8-92.6)	79.3 (76.0-82.5)	0.837 (0.806-0.867)	0.166 (0.152-0.180)
Age	<65	182.8	72.4	76.4 (72.0-80.8)	68.9 (61.1-76.6)	74.5 (61.3-87.6)	71.1 (63.9-78.3)	0.834 (0.807-0.860)	0.165 (0.157-0.174)
	65-74	96.8	58.8	74.1 (66.6-81.6)	74.7 (67.1-82.3)	86.3 (76.3-96.3)	79.9 (72.7-87.1)	0.797 (0.725-0.869)	0.179 (0.158-0.200)
	≥75	137.0	83.2	75.0 (68.5-81.5)	75.9 (67.9-83.9)	86.9 (78.7-95.1)	80.8 (75.5-86.0)	0.812 (0.729-0.896)	0.167 (0.131-0.204)

3) Temporal Holdout 평가

표 5-3은 temporal holdout 평가 데이터 셋의 학습, 검증, 테스트 셋의 분할 구성을 나타낸다. ECG 기록 시점을 기준으로 시간 순서에 따라 7:1:2 비율로 분할하였으며, 각 분할별 기간, 환자 수, ECG 수, 뇌졸중군 및 비뇌졸중군의 ECG 수와 비율을 기재하였다. 시간적 분할은 기록 단위에서 연대순으로 수행되었으므로 인접한 하위 집합 간에 동일한 경계 날짜가 나타날 수 있으나, 이는 동일 날짜에 여러 ECG 기록이 존재하기 때문이며 하위 집합 간 중복 샘플은 없다. 또한 Total patients는 split 간 중복 환자를 제거한 전체 고유 환자 수를 의미한다.

표 5-3. Temporal Holdout 평가 데이터 셋

Split	Period	Patients	ECGs	Stroke (%)	Non-Stroke (%)
Train (7)	2015-01-02 to 2018-10-19	2149	2192	819 (37.36)	1373 (62.64)
Val (1)	2018-10-22 to 2019-03-21	313	313	106 (33.87)	207 (66.13)
Test (2)	2019-03-21 to 2019-12-31	627	627	197 (31.42)	430 (68.58)
Total	2015-01-02 to 2019-12-31	3066	3132	1122 (35.82)	2010 (64.18)

표 5-4는 temporal holdout 테스트 셋에서 각 모델의 분류 성능을 비교한 결과이다. 해당 평가는 단일 시간 분할에 기반하므로, 5-fold 교차 검증 결과와 달리 95% 신뢰구간은 제시하지 않고 각 지표의 결과값만 제시하였다.

표 5-4. Temporal Holdout 분류 성능

Model	Accuracy	Precision	Recall	F1-score	AUC	Brier
Feature-Only	57.7	39.2	62.9	48.3	0.636	0.243
Signal-Only	71.6	56.5	42.1	48.3	0.718	0.191
Interaction Early Fusion	70.5	52.6	62.4	57.1	0.751	0.230
Hybrid Fusion	62.5	44.8	83.2	58.3	0.758	0.199